La discrétisation

Découper une série en classes

Florian Bayer - M2 IGAST

Géodata Paris
l'école des ingénieur·es géographes

Objectifs de la séance

- Comprendre pourquoi une carte en aplats se fait toujours avec des classes
- Décrire la distribution d'une série avant de choisir une méthode
- Connaître les méthodes automatiques (quantiles, Q6, amplitudes égales, moyenne et écart-type, Jenks) et les seuils thématiques
- Choisir le nombre de classes et arrondir les limites
- Comparer deux cartes de façon absolue ou relative

Fil rouge, la densité de population des 96 départements de France métropolitaine en 2022 (Insee).

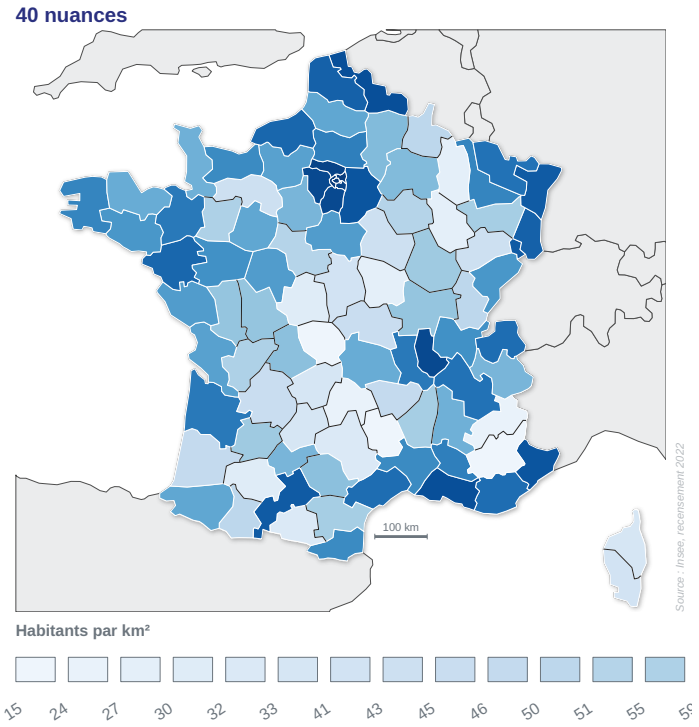
1 - Pourquoi discrétiser

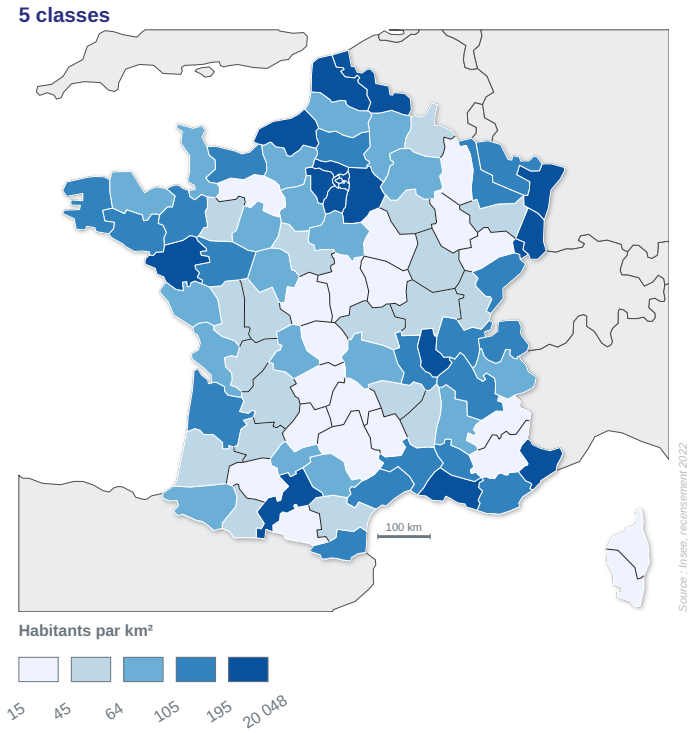
L'œil lit un ordre, pas une valeur

- Continu ou discret
- Ce que doivent faire les classes
- Un choix qui fait le message



Une gamme continue ou des classes





- À gauche, presque une nuance par département. On devine les grandes villes, mais impossible de retrouver une valeur
- À droite, 5 classes. Chaque palier de valeur renvoie à un intervalle de la légende
- La **discrétisation** découpe une série continue en classes

Pourquoi des classes

L'œil lit un ordre

La valeur (du clair au foncé) ne transmet qu'un ordre

Sur une carte en aplats, 8 à 9 paliers sont un repère (Bertin), selon la taille, le support et le contraste

Toujours des classes

Les classes associent un palier de valeur à un intervalle de la légende

Une gamme continue ne se lit pas, même pour explorer

Une perte choisie

Discrétiser réduit l'information pour qu'elle soit lisible

Le choix de la méthode décide de ce qui est perdu

Des classes homogènes et bien séparées

Classes homogènes, variance intra-classe 0,43



Classes mal placées, variance intra-classe 3,64



Un objectif possible, des groupes homogènes. Deux classes voisines sont alors nettement différentes.

- Minimiser la **variance intra-classe**, maximiser la **variance inter-classe**
- La variance totale (13,06) est la somme des deux. Réduire l'une augmente l'autre
- D'autres objectifs sont légitimes. Des effectifs équilibrés, des seuils interprétables

Les règles de construction

Le découpage suit les mêmes règles qu'en statistique.

Couvrir

Les classes vont du minimum au maximum de la série

Sans trou

Elles sont contiguës

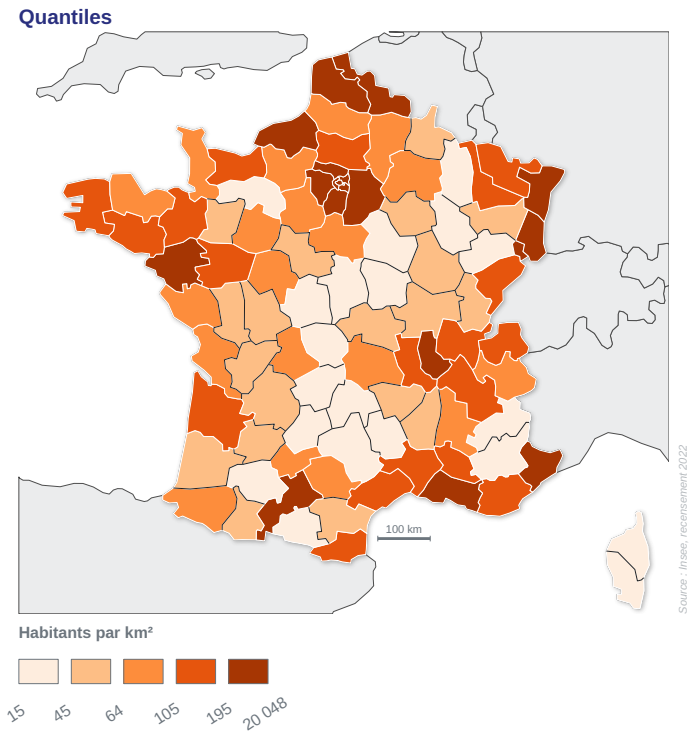
Une valeur appartient à une seule classe

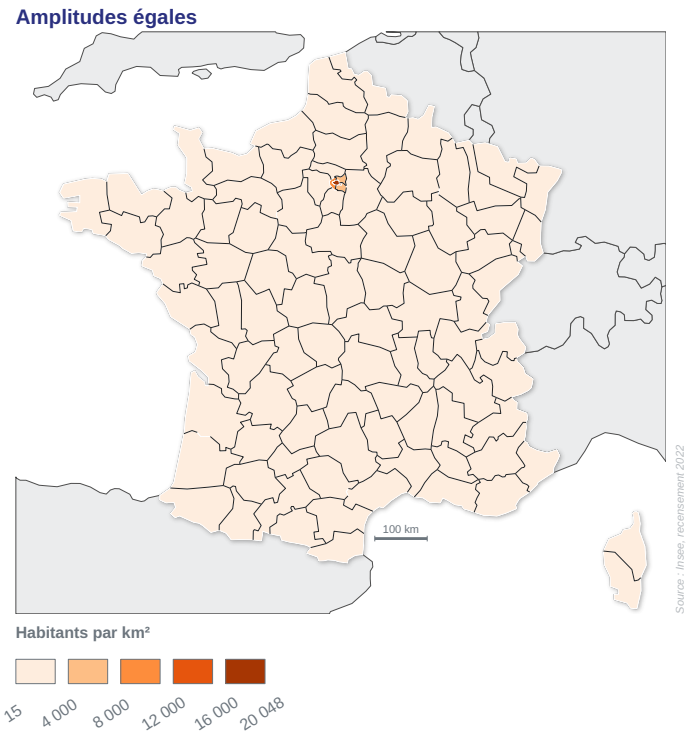
Sans vide

On évite les classes vides

Sauf pour comparer des cartes avec des bornes communes

Le choix de la méthode





- Mêmes données, 5 classes, deux méthodes
- Avec les quantiles, la France se partage entre départements ruraux clairs et départements urbains foncés
- Avec des amplitudes égales, 92 départements sur 96 tombent dans la première classe. Seuls Paris et la petite couronne ressortent
- Les deux cartes sont justes. Elles ne répondent pas à la même question

2 - Décrire la série

Regarder la distribution avant de choisir

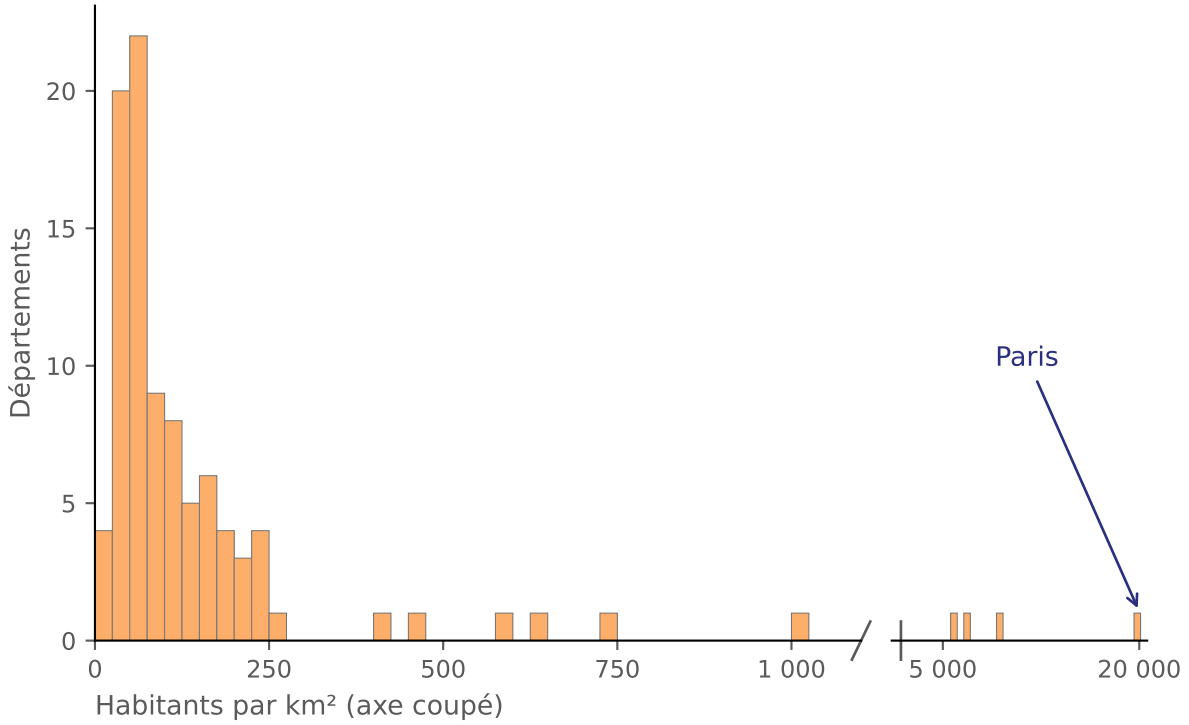
- Valeurs centrales et dispersion
- Une distribution étalée à droite



Les questions à se poser

Le message	Montrer la répartition statistique, ou des seuils qui ont un sens (zéro, une norme, une moyenne) ?
La comparaison	La carte sera-t-elle comparée à une autre date, ou à un autre indicateur ?
Le public	A-t-il besoin de classes simples et arrondies, quitte à perdre une partie de l'information ?
La série	Quelle forme a sa distribution ? Où sont les valeurs extrêmes ?

La série du fil rouge



Indicateur	Valeur
Départements	96
Minimum (Lozère)	15
Médiane	83
Moyenne	565
Écart-type	2 387
Maximum (Paris)	20 048
Asymétrie	6,5

Une distribution étalée à droite

Moyenne et médiane

La moyenne (565 hab./km^2) vaut près de sept fois la médiane (83)

Quelques valeurs très fortes la tirent vers le haut

Répartition

La moitié des départements ont moins de 83 habitants par km^2, les trois quarts moins de 163

Paris (20 048), les Hauts-de-Seine (9 383) et la Seine-Saint-Denis (7 100) sont loin devant

Conséquence

C'est une distribution étalée à droite, fréquente pour les densités, les revenus ou les tailles de villes

Les méthodes ne placeront pas du tout les limites au même endroit

3 - Les méthodes

Placer les limites des classes

- Quantiles et Q6
- Amplitudes égales
- Moyenne et écart-type
- Seuils naturels (Jenks)
- Une autre série
- Des seuils qui ont un sens



Les quantiles (effectifs égaux)

Même nombre d'unités dans chaque classe. 96 départements ÷ 5 classes, 19 ou 20 par classe.

Avantages

Très simple à construire et à expliquer

Chaque palier de valeur couvre la même part des unités

Applicable à toutes les distributions

Permet de comparer des rangs entre deux séries

Limites

Ne suit pas la forme de la distribution

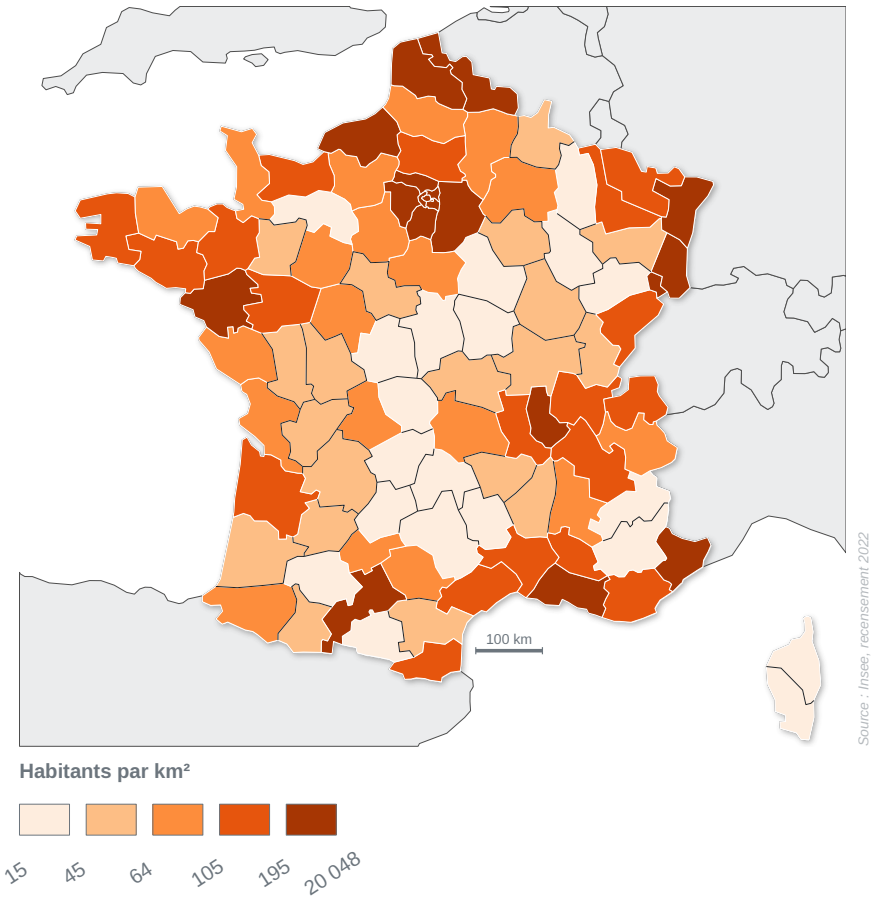
La dernière classe va de 195 à 20 048 hab./km²

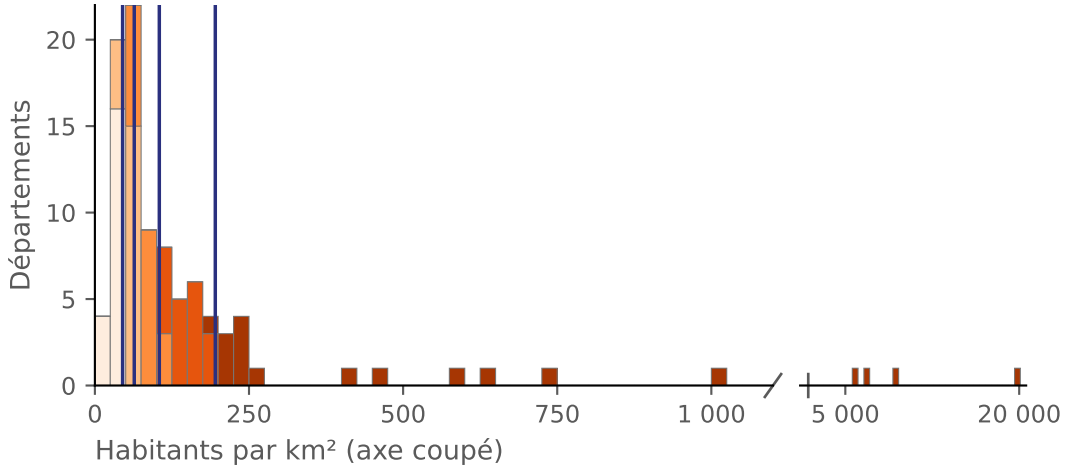
Le Territoire de Belfort y côtoie Paris

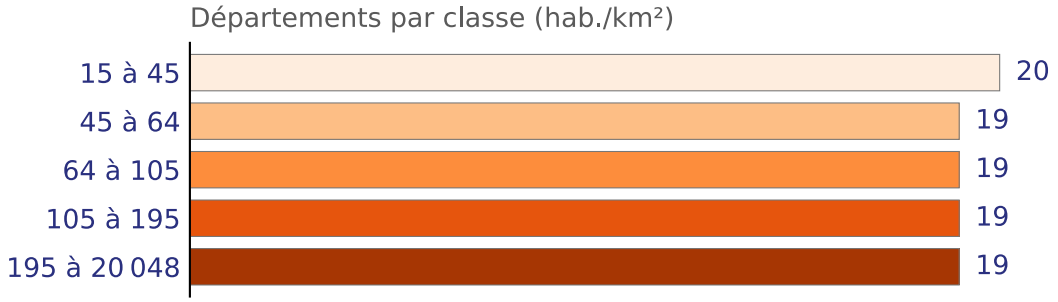
Les ex æquo restent dans la même classe, les effectifs ne sont alors plus égaux

Deux valeurs proches peuvent tomber dans deux classes

Les quantiles (effectifs égaux)







Les quantiles, variante Q6

Des quartiles dont les deux classes extrêmes sont isolées. 5 %, 20 %, 25 %, 25 %, 20 %, 5 % des unités.

Avantages

Simple et applicable à toutes les distributions

Met en évidence les extrêmes

Ici les 5 départements au-dessus de 800 hab./km² (Paris, la petite couronne, le Val-d'Oise) et les 5 sous 27

Limites

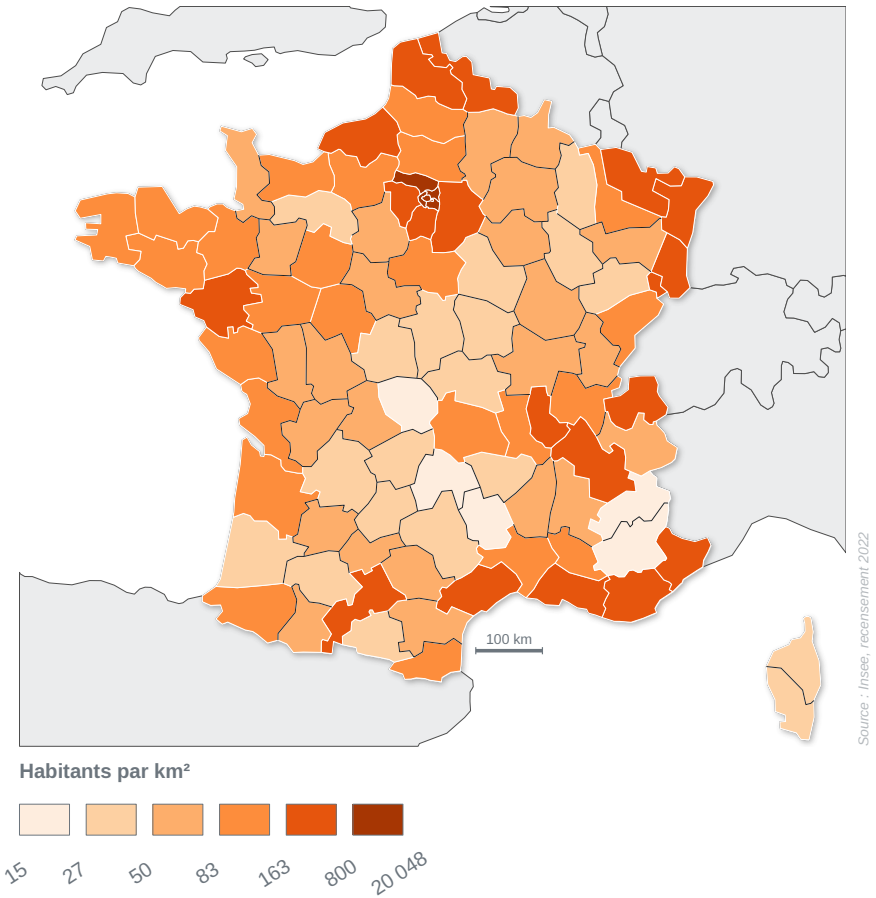
Toujours 6 classes

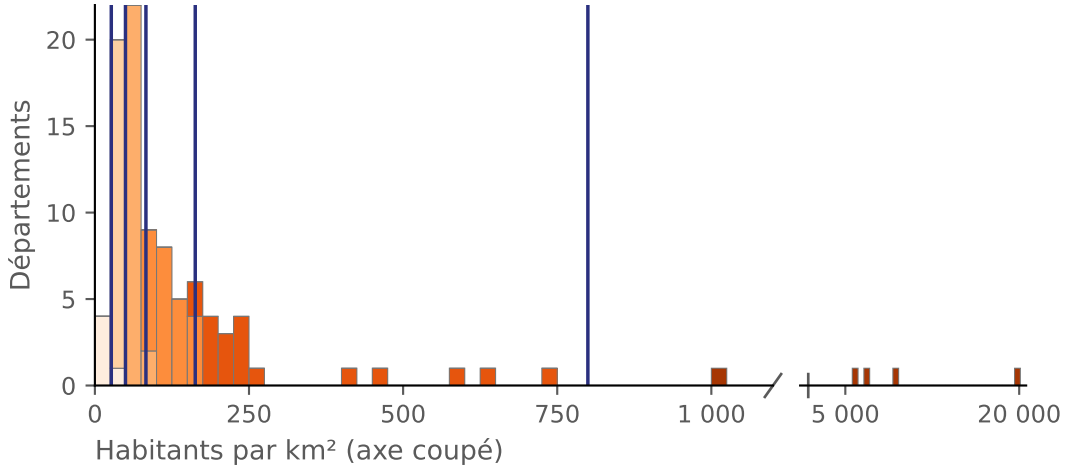
Moins connue du lecteur

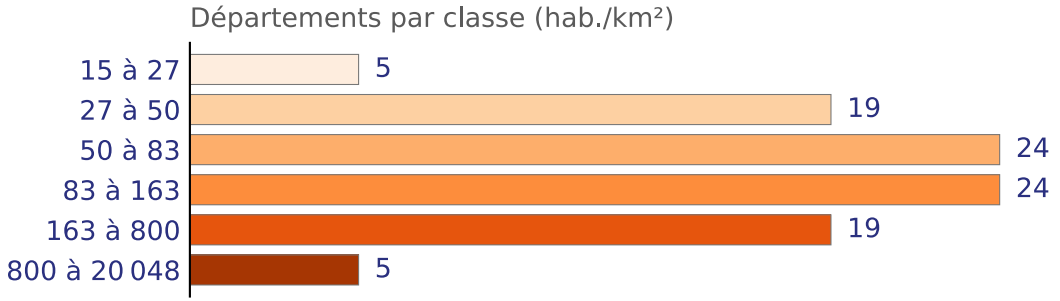
Proposée par Philcarto et Magrit

Dans QGIS, les bornes se calculent à la main

Les quantiles, variante Q6







= Les amplitudes égales

Des classes de même largeur. (maximum − minimum) ÷ 5 = 4 007 hab./km², arrondi à 4 000. Limites à 4 000, 8 000, 12 000 et 16 000.

Avantages

Très simple à comprendre

Adaptée à une distribution uniforme

Des limites arrondies parlent au grand public

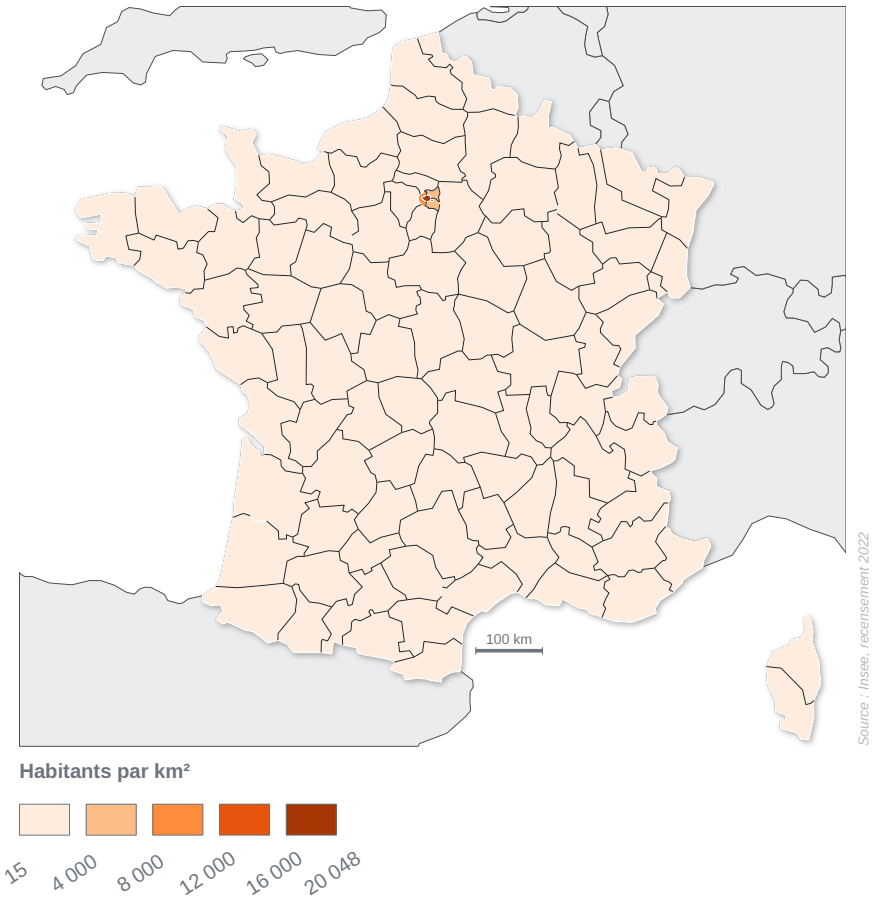
Limites

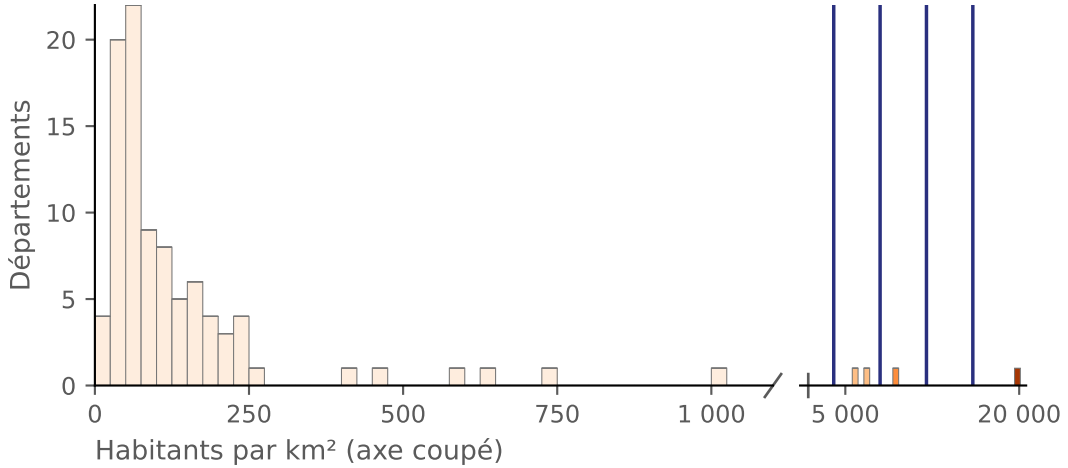
Très mal adaptée à une série étalée à droite

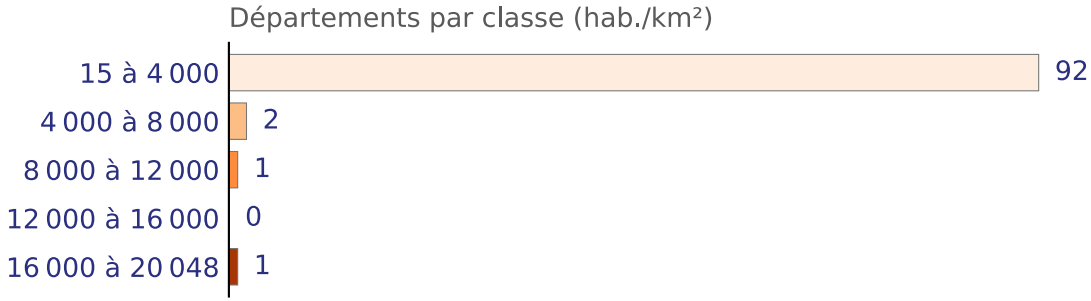
92 départements sur 96 dans la première classe, une classe vide

Paris suffit à fixer toutes les limites

= Les amplitudes égales







La moyenne et l'écart-type

La moyenne au centre de la classe centrale, des classes d'un écart-type (σ) de large. Limites à moyenne ± 0,5σ et ± 1,5σ.

Avantages

Montre l'écart à la moyenne

La classe centrale est neutre, les classes extrêmes isolent les valeurs « anormales »

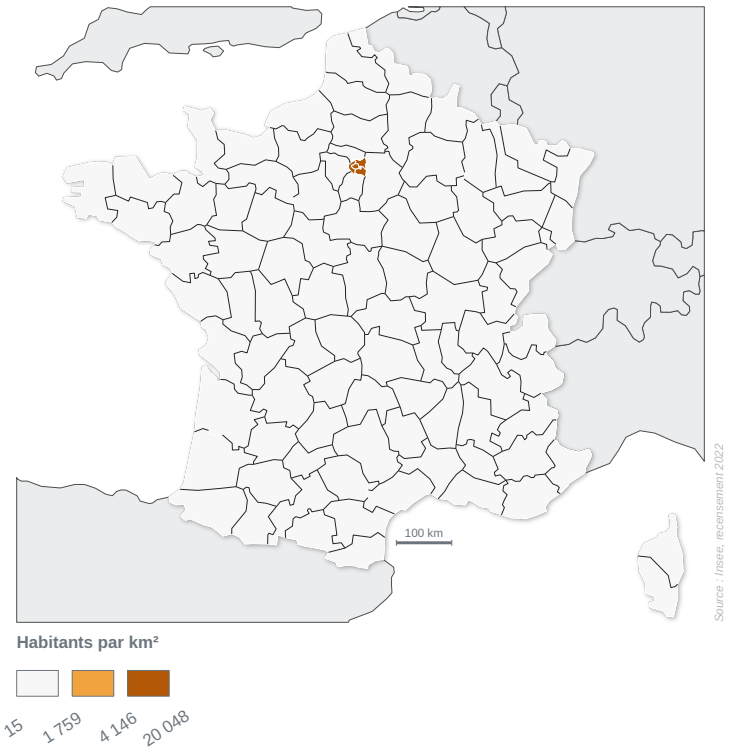
Permet de comparer deux séries normales de moyennes et d'écarts-types proches

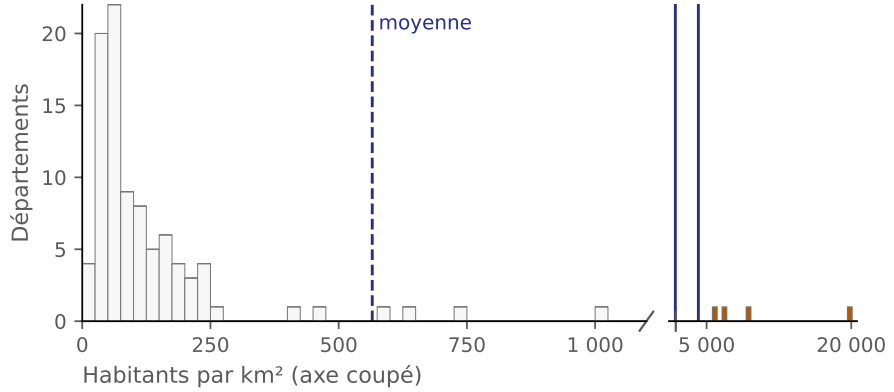
Limites

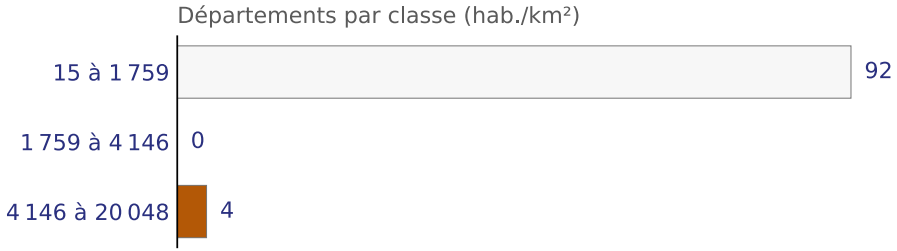
Plus lisible sur une distribution assez symétrique

Sur une série étalée à droite, des limites tombent sous le minimum, des classes disparaissent

Moyenne et écart-type, sur la densité brute



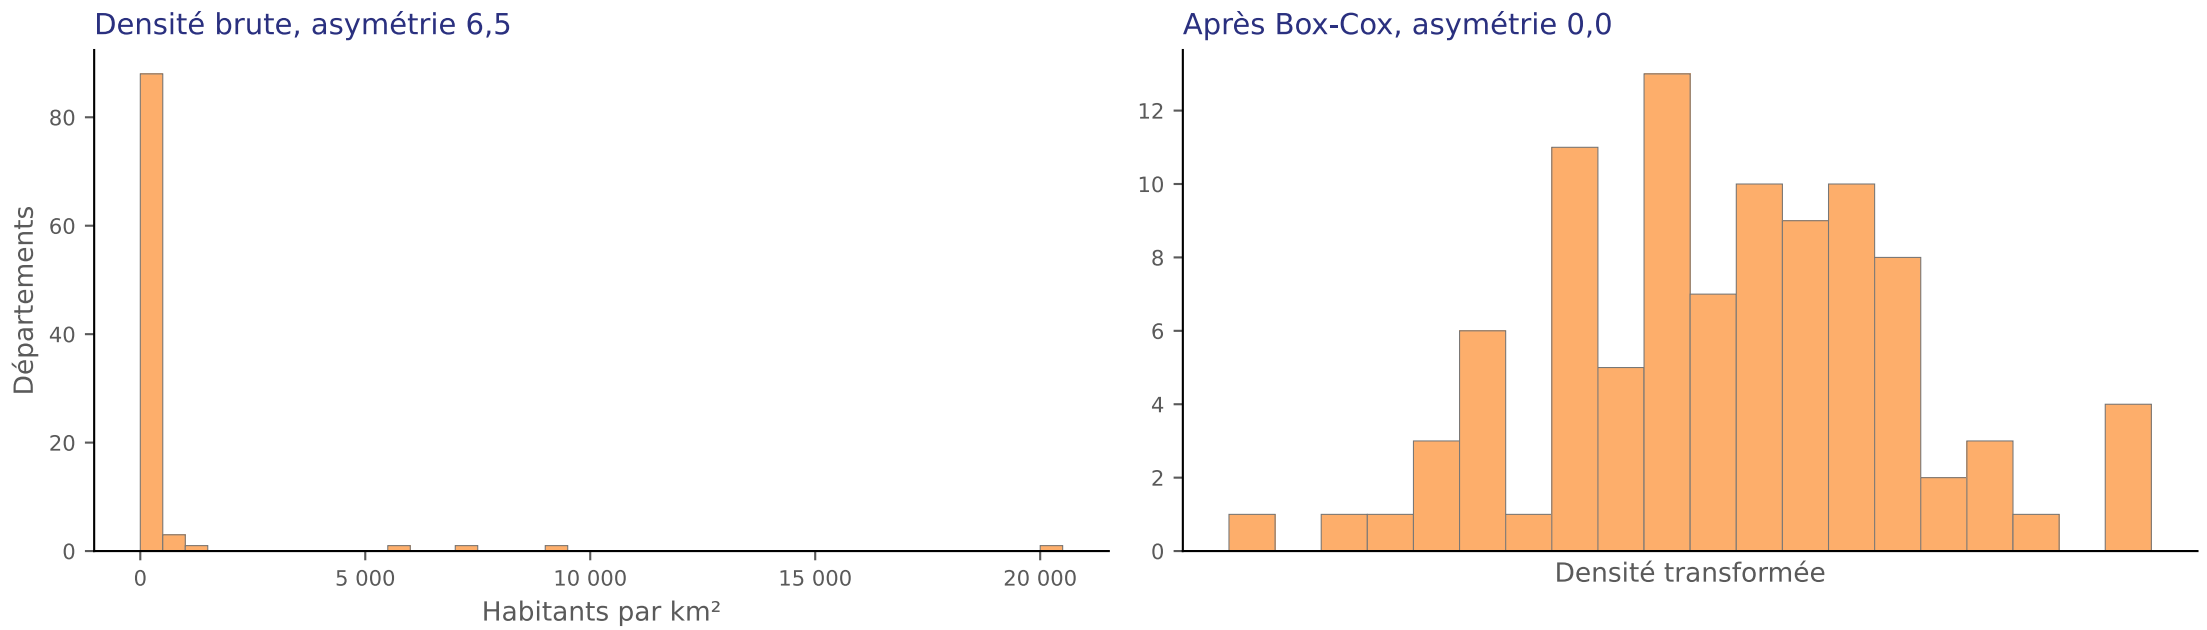




Moyenne m = 565, σ = 2387	m − 1,5σ	m − 0,5σ	m + 0,5σ	m + 1,5σ
Calcul	565 − 3 581	565 − 1 194	565 + 1 194	565 + 3 581
Limite (hab./km²)	-3 015, sous le minimum	-628, sous le minimum	1 759	4 146

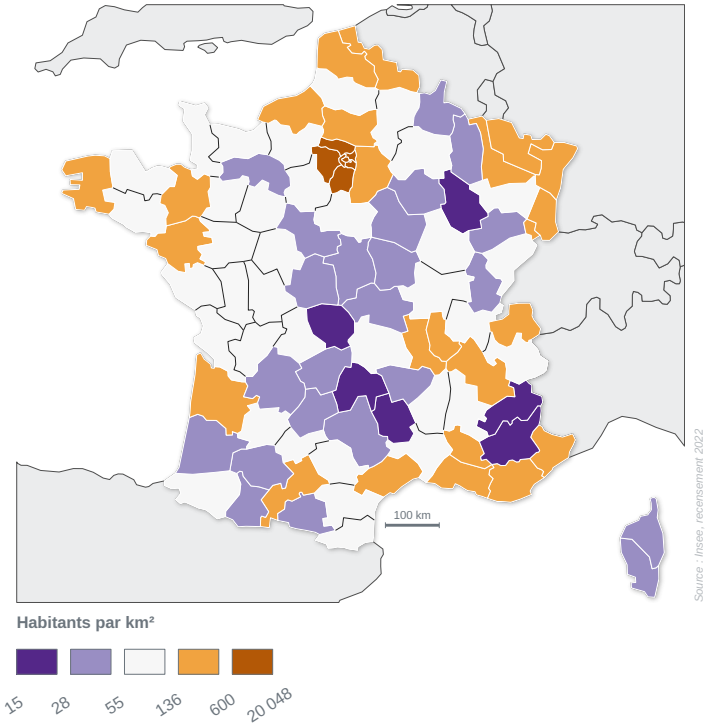
Deux limites tombent sous le minimum (15). Il ne reste que 3 classes, dont une de 92 départements.

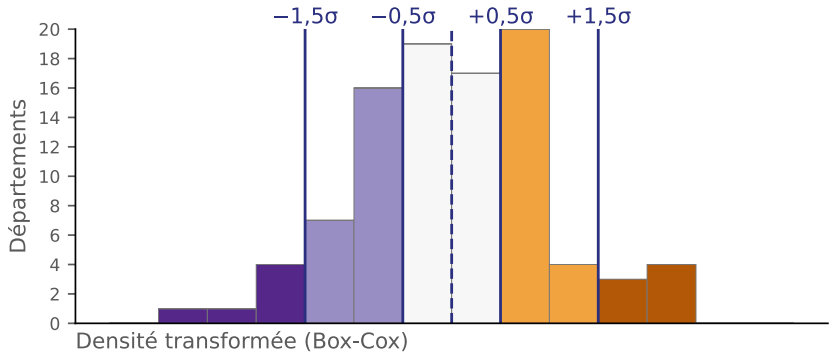
Réduire l'asymétrie

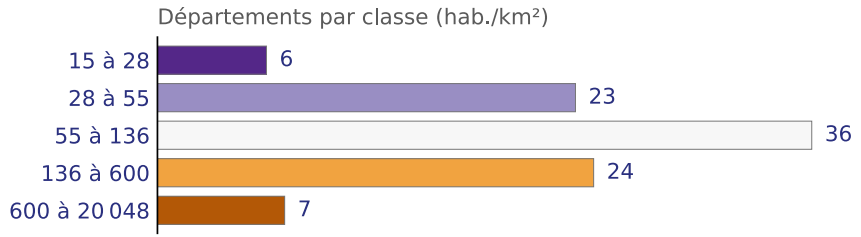


- La transformation de Box-Cox élève la densité à une puissance λ, estimée sur les données pour réduire l'asymétrie. Ici λ = −0,42
- Elle suppose des valeurs strictement positives. Elle ne garantit pas une série normale. On vérifie le résultat sur l'histogramme
- On calcule les limites sur la série transformée, puis on les ramène en hab./km² par la transformation inverse

Moyenne et écart-type, après transformation







Série transformée, m = 2,017, σ = 0,142	m − 1,5σ	m − 0,5σ	m + 0,5σ	m + 1,5σ
Limite transformée	1,803	1,945	2,088	2,230
Ramenée en hab./km²	28	55	136	600

La classe centrale regroupe les départements proches de la moyenne de la série transformée (83 hab./km² une fois ramenée), pas de la moyenne des densités (565).

Les seuils naturels (Jenks)

Un algorithme cherche les limites qui minimisent la variance intra-classe (Jenks, 1967 ; Fisher, 1958).

Avantages

Suit au mieux la forme de la distribution

Regroupe les valeurs semblables et isole les extrêmes (Paris seul dans sa classe)

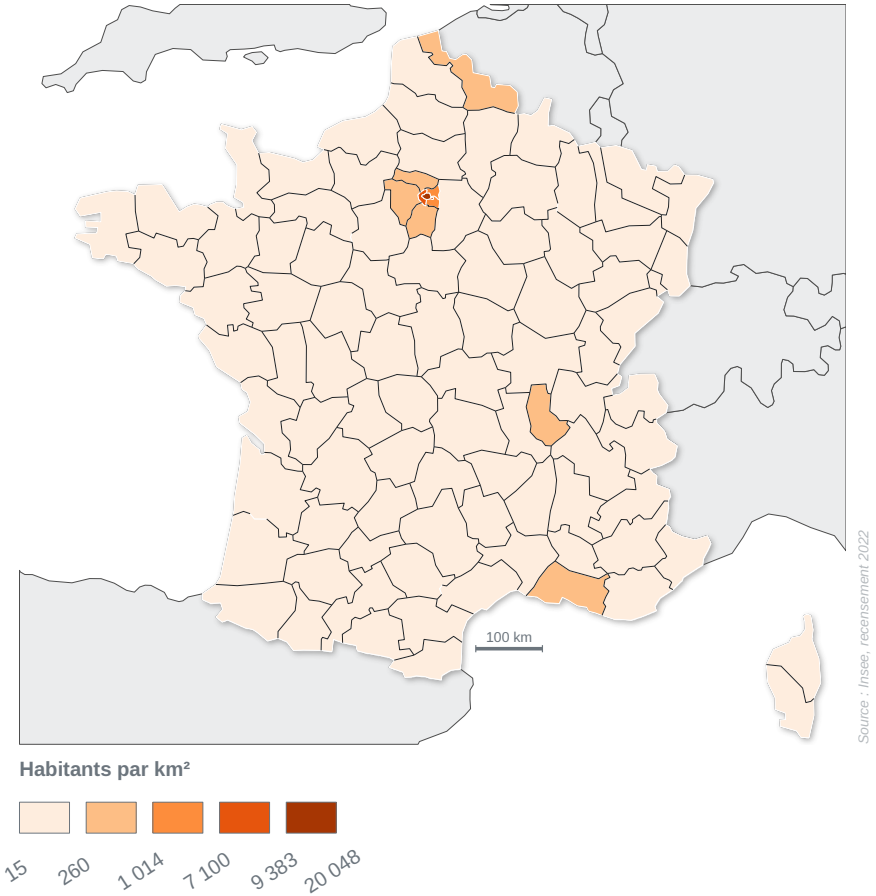
Limites

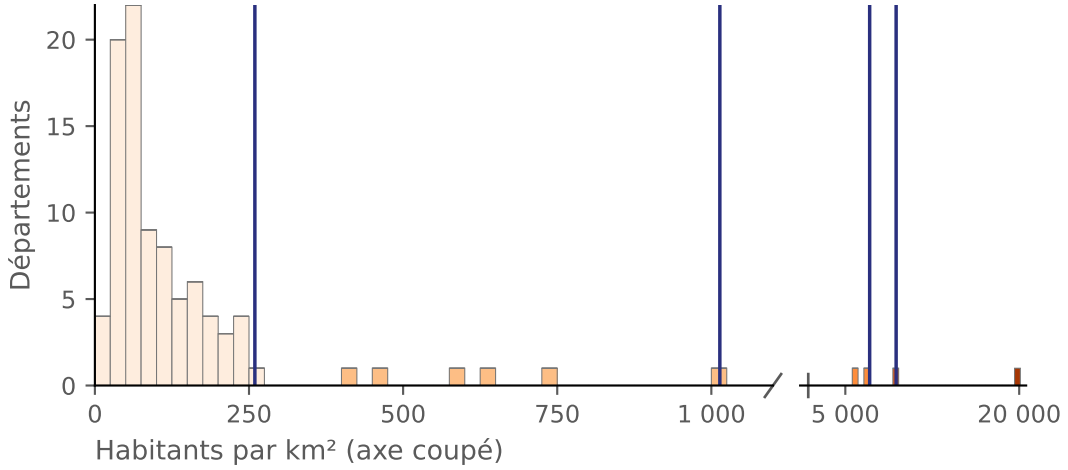
Sur une série très étalée, l'algorithme consacre presque toutes les classes aux valeurs fortes

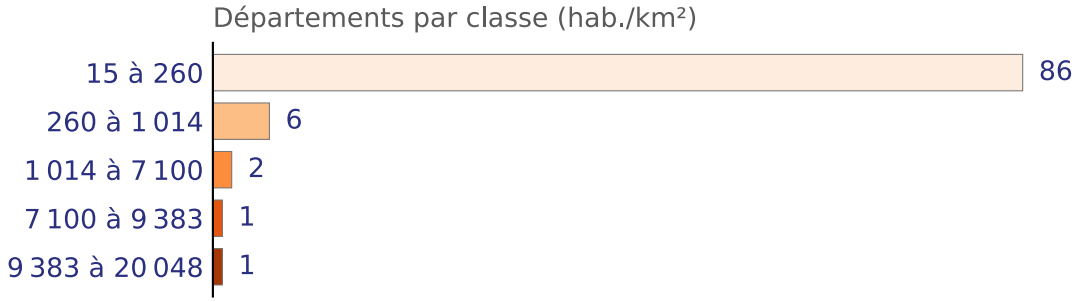
86 départements partagent la première

Limites propres à chaque série, à arrondir

Les seuils naturels (Jenks)

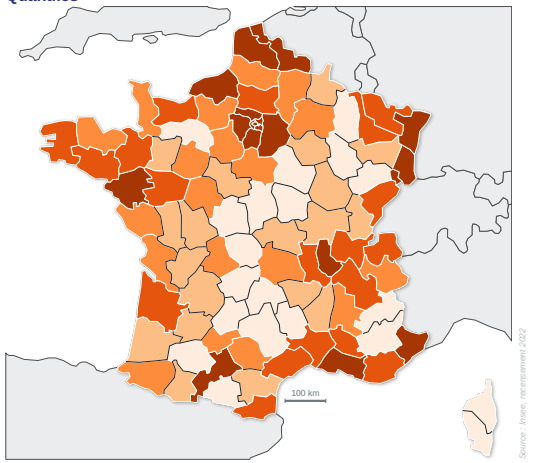




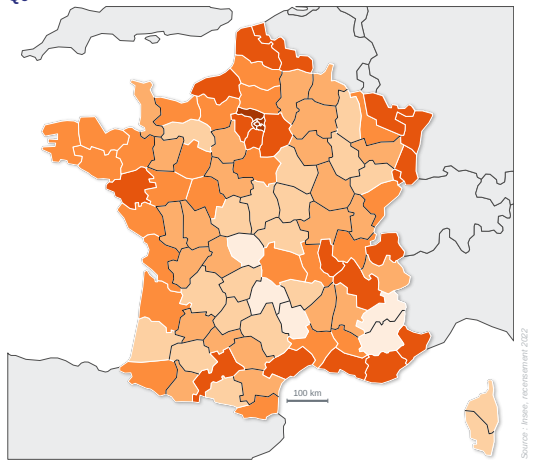


Comparaison de cinq méthodes

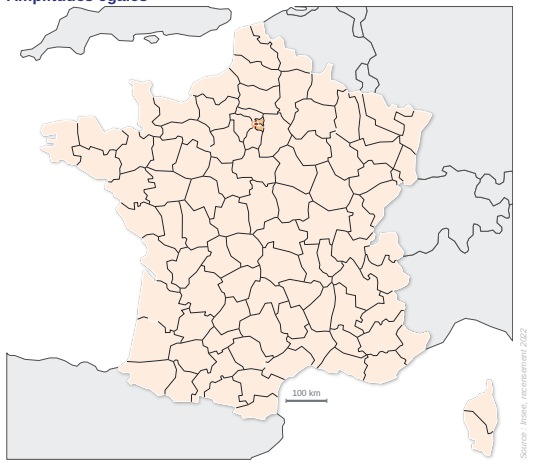
Quantiles



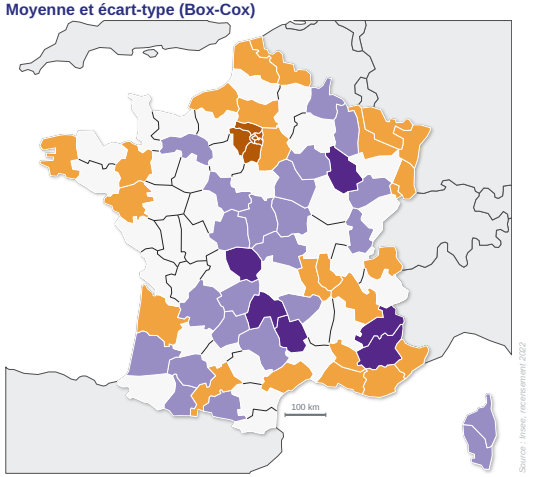
Q6



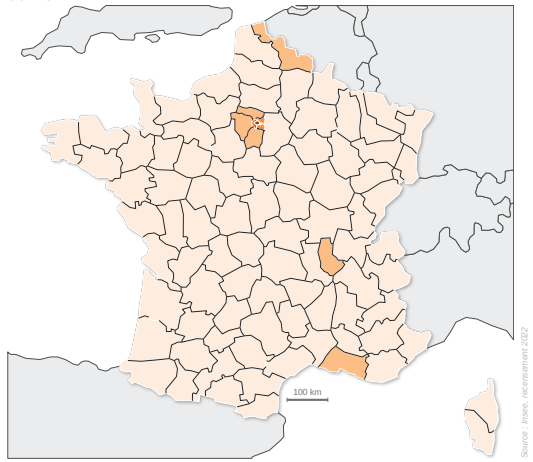
Amplitudes égales



Moyenne et écart-type (Box-Cox)

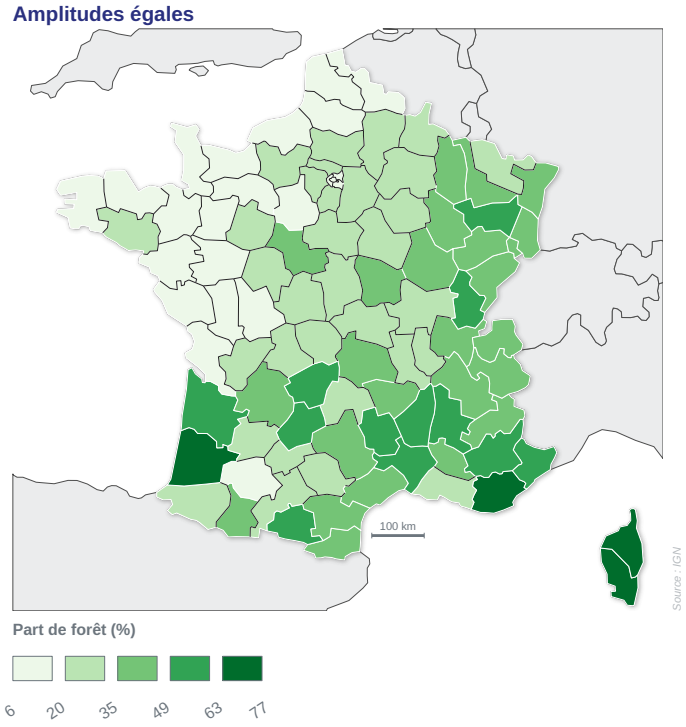


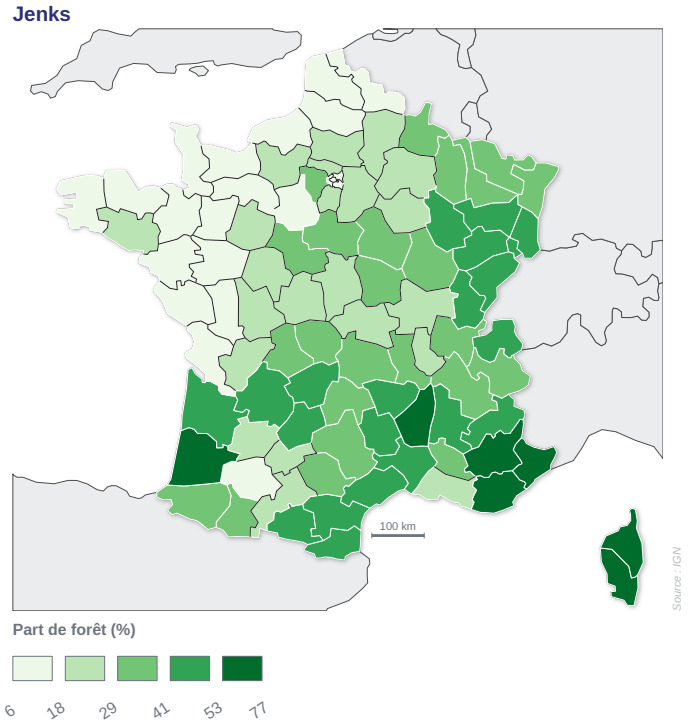
Jenks



- Amplitudes égales et Jenks ne montrent que l'Île-de-France
- Quantiles, Q6 et écart-type (après transformation) font apparaître les métropoles et la « diagonale du vide »
- Ce classement vaut pour cette série très dissymétrique, pas pour toutes

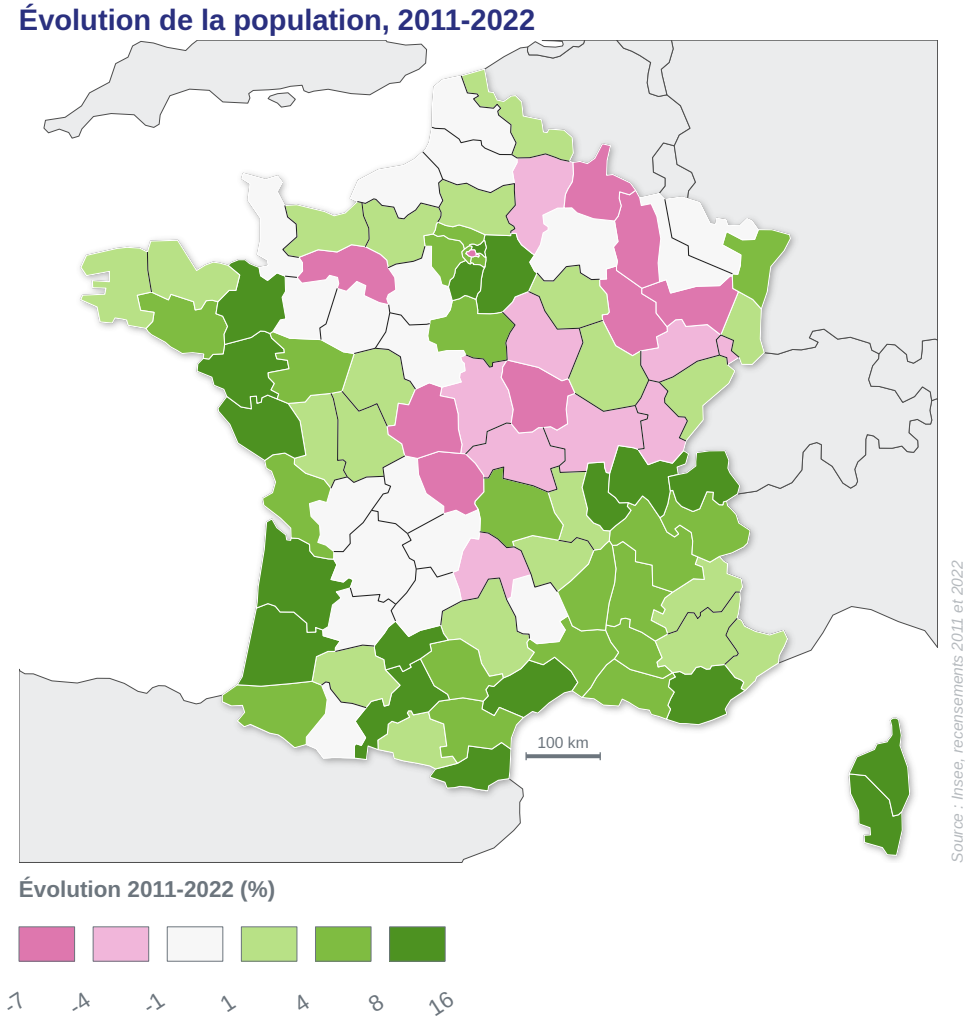
Une autre série : la part de forêt





- La part de forêt est peu dissymétrique (asymétrie 0,5, contre 6,5 pour la densité)
- Les amplitudes égales donnent ici des classes bien remplies (23, 32, 25, 12, 4 départements)
- Jenks place ses limites près de celles des amplitudes égales
- Une méthode peu convaincante sur la densité peut convenir ailleurs. Le choix dépend de la série

Seuils thématiques



- Les limites ne viennent pas d'un algorithme. Elles suivent le sens de l'indicateur
- Zéro sépare les départements qui perdent des habitants de ceux qui en gagnent. La classe centrale (−1 à +1 %) regroupe les 19 départements presque stables
- D'autres seuils thématiques. Une norme réglementaire, la moyenne nationale, un objectif de politique publique
- Des limites arrondies, qui se lisent et se comparent facilement

4 - Questions fréquentes

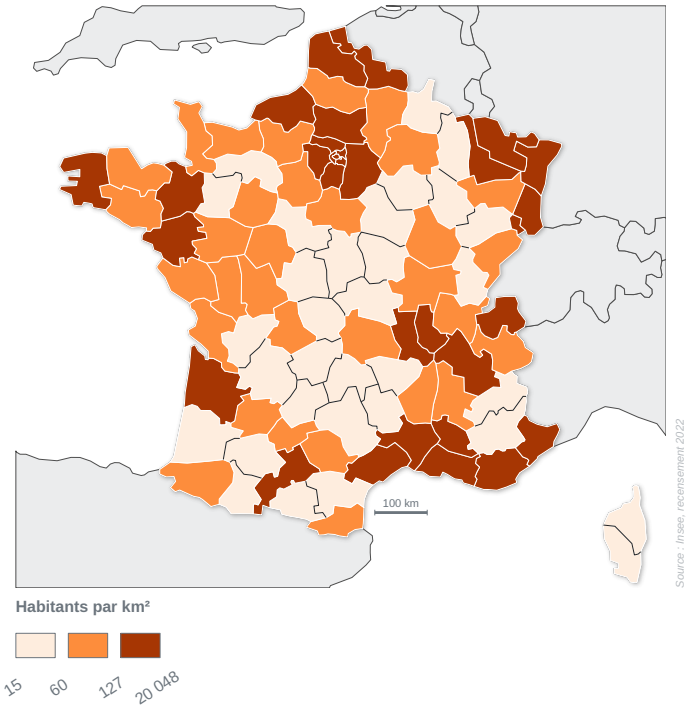
Classes, arrondis, comparaisons

- Combien de classes ?
- Faut-il arrondir ?
- Comparer deux cartes

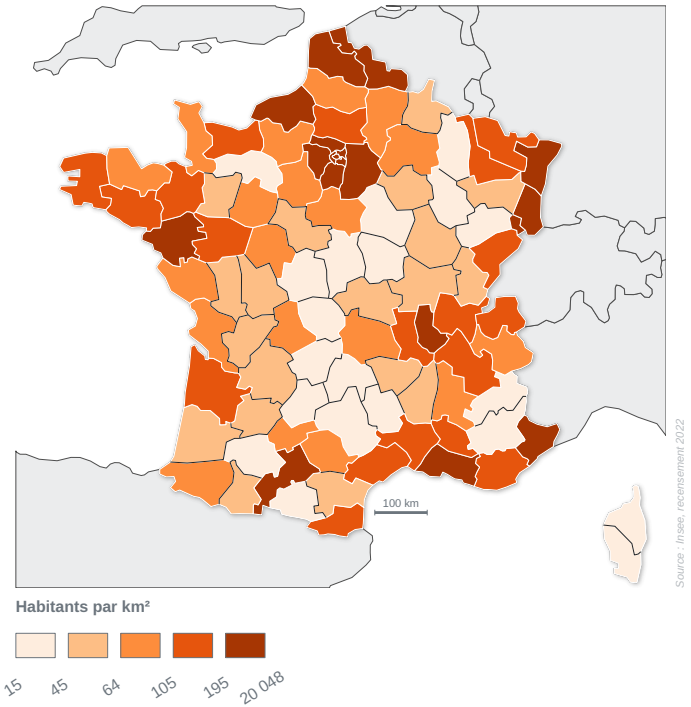


Combien de classes ?

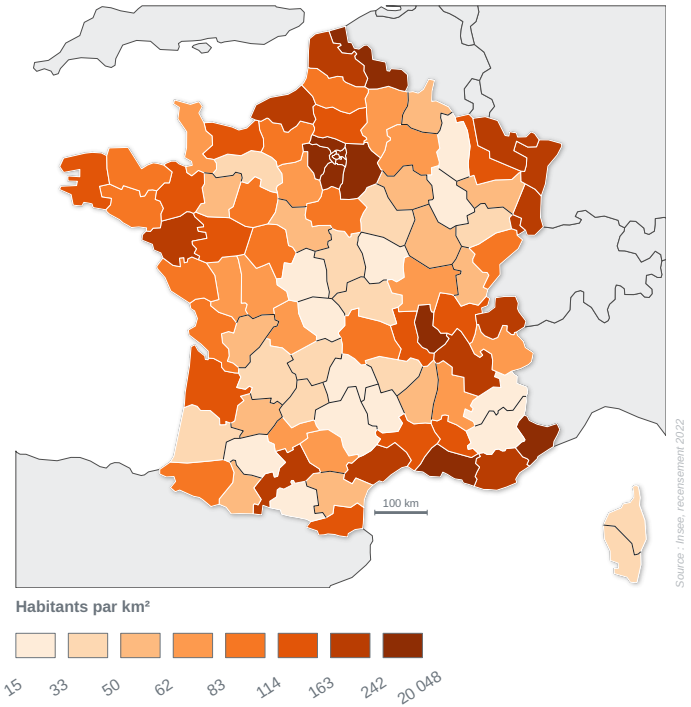
3 classes



5 classes



8 classes



- Quantiles dans les trois cas. Avec 3 classes, l'information spatiale est trop pauvre. Avec 8, les oranges voisins se confondent
- En cartographie, 4 à 7 classes. 5 classes est un bon point de départ

Arrondir les limites

Limites calculées (quantiles)	Effectif	Limites arrondies	Effectif
14,79 à 44,95	20	14,79 à 45	20
44,95 à 63,87	19	45 à 65	19
63,87 à 104,51	19	65 à 100	16
104,51 à 195,32	19	100 à 200	23
195,32 à 20048,14	19	200 à 20 048	18

- Arrondir l'affichage ne change rien. Déplacer une borne de classement, si. Une unité peut changer de classe
- Le minimum et le maximum restent les vrais. Arrondir 14,79 en 15 laisserait la Lozère hors des classes
- Convention de mapclassify et de QGIS, la limite supérieure est incluse.]45 ; 65] puis]65 ; 100]
- Arrondir **avant** la mise en page, dans le logiciel de cartographie, puis vérifier que chaque unité a une classe

Comparer deux cartes

Comparaison absolue

Des données de même nature (même indicateur, deux dates ou deux territoires)

Mêmes limites de classes sur les deux cartes

Un même palier de valeur = un même intervalle

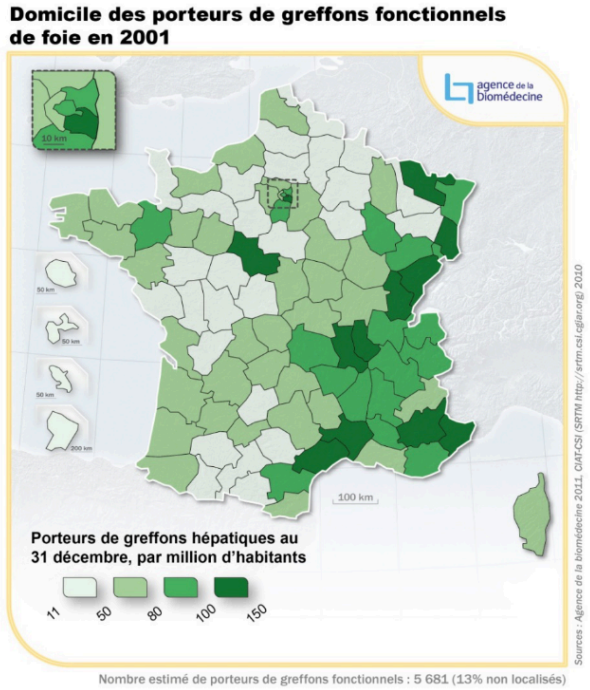
Comparaison relative

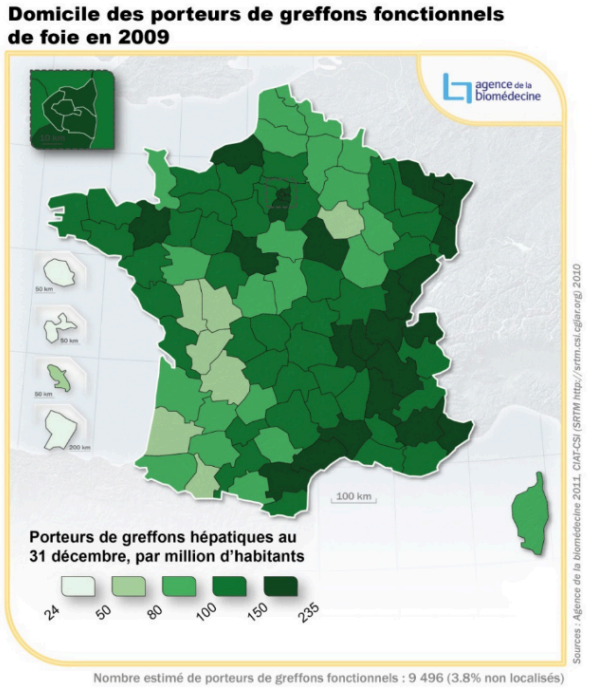
Des données de nature différente

Mêmes fréquences dans les classes (quantiles, Q6)

Un même palier de valeur = une même position dans la série

= Comparaison absolue, deux dates

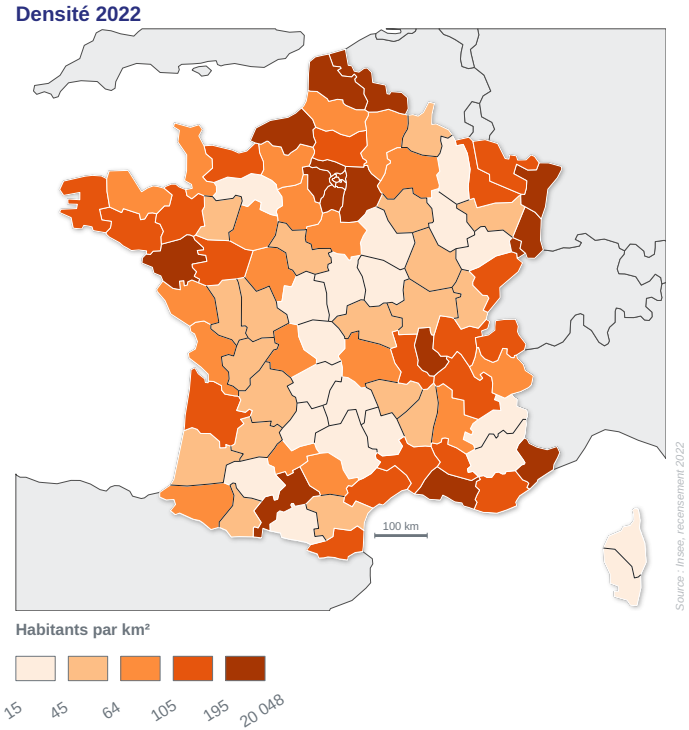


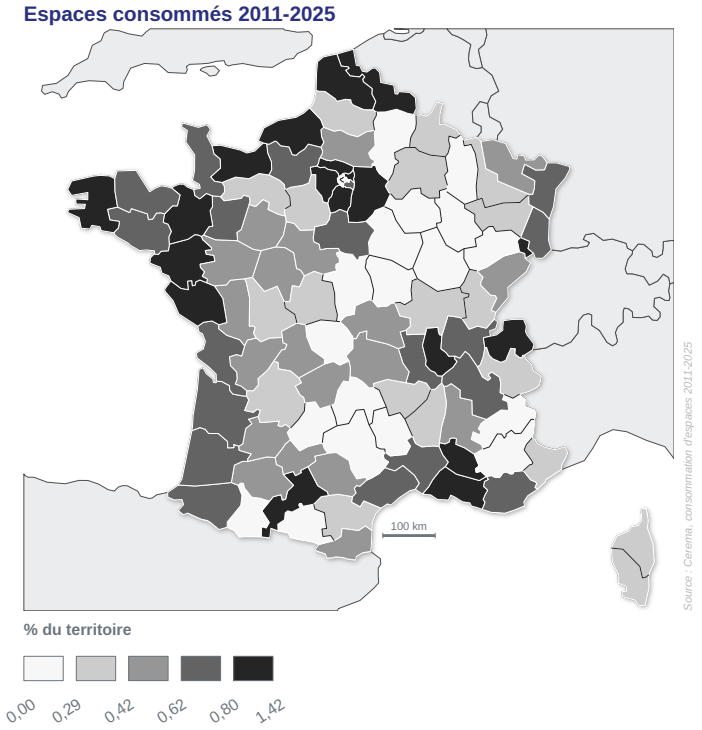


Agence de la biomédecine, 2011

- Porteurs d'un greffon de foie fonctionnel, par million d'habitants, en 2001 et en 2009
- Limites de Jenks calculées en 2001 (50, 80, 100), reprises en 2009
- Le minimum est ajusté (11 en 2001, 24 en 2009)
- Une classe est ajoutée en 2009 (150 à 235)
- Un même vert désigne la même valeur. L'augmentation se lit d'une carte à l'autre

Comparaison relative, deux indicateurs





- Deux mesures de la pression urbaine, sans unité commune. Quintiles sur chaque carte
- Une valeur foncée désigne les 20 % de départements aux valeurs les plus fortes
- 13 départements sont dans le dernier quintile des deux séries (Nord, Rhône, Haute-Garonne, grande couronne...). 14 sont dans le premier des deux
- Paris et les Hauts-de-Seine, très denses, consomment peu. Il ne reste presque plus d'espace à bâtir

Conclusion

Choisir et justifier

- Quelle méthode pour quel besoin
- Ce qu'il faut retenir



Quelle méthode pour quel besoin

Des positions relatives

Quantiles, ou Q6 pour garder les extrêmes

Une règle explicite et reproductible, qui ne garantit pas à elle seule une présentation impartiale

Suivre la distribution

Jenks

La carte ne se compare pas à une autre sans reprendre ses limites

Des seuils qui ont un sens

Zéro, une norme, la moyenne nationale

Pour le grand public, des limites arrondies, ou des amplitudes égales si la distribution s'y prête

Montrer les écarts

Moyenne et écart-type

Plus lisible sur une série assez symétrique, ou après réduction de l'asymétrie

Comparer

Mêmes limites pour des données de même nature

Mêmes fréquences (quantiles) sinon

La méthode

Pas d'obligation de la préciser dans la légende

Pour un rendu scientifique, elle figure dans la méthodologie, pour que la carte puisse être refaite

Ce qu'il faut retenir

Pourquoi	Les classes associent un palier de valeur à un intervalle
	L'œil ne lit qu'un ordre, sur 8 à 9 paliers environ
	Jamais de gamme continue
Avant	Décrire la série d'abord (forme, valeurs centrales, dispersion, extrêmes)
Choisir	La méthode dépend du message, du public et de la comparaison voulue
	Les classes peuvent être ajustées à la main si c'est justifié (autour de zéro, d'une norme)
Présenter	Arrondir les limites et garder le vrai minimum et le vrai maximum
	Pour un rendu scientifique, la méthode figure dans la méthodologie

Bibliographie

Fisher, W. D. (1958). On grouping for maximum homogeneity. *Journal of the American Statistical Association*, 53(284), 789-798.

Box, G. E. P., Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society, Series B*, 26(2), 211-252.

Jenks, G. F. (1967). The data model concept in statistical mapping. *International Yearbook of Cartography*, 7, 186-190.

Tobler, W. R. (1973). Choropleth maps without class intervals? *Geographical Analysis*, 5(3), 262-265.

Brewer, C. A., Pickle, L. (2002). Evaluation of methods for classifying epidemiological data on choropleth maps in series. *Annals of the Association of American Geographers*, 92(4), 662-681.

Zanin, C., Trémélo, M.-L. (2003). *Savoir faire une carte.* Belin, Paris.

Lambert, N., Zanin, C. (2016). *Manuel de cartographie. Principes, méthodes, applications.* Armand Colin, Paris.

Béguin, M., Pumain, D. (2017). *La représentation des données géographiques. Statistique et cartographie*, 4e éd. Armand Colin, Paris.

Cerema (2025). *Consommation d'espaces naturels, agricoles et forestiers du 1er janvier 2011 au 1er janvier 2025.* Données communales, data.gouv.fr.

TD - Le choix des classes

Feuillus et conifères en France

- La commande
- Quatre groupes, quatre méthodes
- Ce qu'il faut rendre
- Un choix individuel



Consigne

Le groupe de travail sur la forêt (TD précédent) veut comparer la part des conifères et celle des feuillus dans les forêts françaises.

- Deux cartes choroplèthes, colonnes p_feuillus et p_conifere du fichier DEP_FORET_3857.geojson
- Quatre groupes. Les méthodes sont attribuées au hasard aux groupes. Chaque groupe dit quand sa méthode fonctionne et quand il la déconseille
- Feuillus et conifères ne font pas 100 %. La forêt compte aussi des peuplements mixtes et des surfaces sans couvert

Quantiles

Effectifs égaux

Q6

Extrêmes isolés

Amplitudes égales

Largeurs égales, arrondies

Seuils naturels

Jenks

Rendu

Chaque groupe présente en quelques minutes.

- La distribution des deux séries (histogramme, valeurs centrales, dispersion)
- Les deux cartes, mises en page
- Les bornes, les effectifs par classe et la place des valeurs extrêmes
- Une décision explicite, comparaison absolue ou relative. Les deux séries sont des pourcentages, des classes communes sont à essayer

Après la restitution

Chaque étudiant choisit, seul, la méthode et le mode de comparaison qu'il retiendrait pour le rapport du groupe de travail. Il justifie ce choix en quelques lignes, à partir des quatre restitutions.