# La discrétisation

## Découper une série en classes

Florian Bayer - M2 IGAST

Géodata Paris
l'école des ingénieur·es géographes

# Objectifs de la séance

- Comprendre pourquoi un taux se découpe en classes avant d'être cartographié
- Décrire la distribution d'une série avant de choisir une méthode
- Connaître cinq méthodes (quantiles, Q6, amplitudes égales, moyenne et écart-type, Jenks), leurs forces et leurs limites
- Choisir le nombre de classes et arrondir les limites
- Comparer deux cartes de façon absolue ou relative

Fil rouge, la densité de population des 96 départements de France métropolitaine en 2022 (Insee).

# 1 - Pourquoi discrétiser

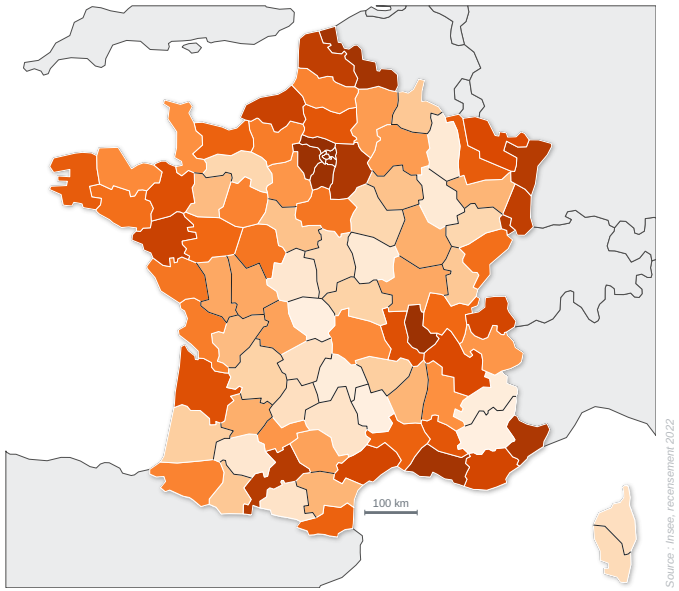
L'œil lit un ordre, pas une valeur

- Continu ou discret
- Ce que doivent faire les classes
- Un choix qui fait le message

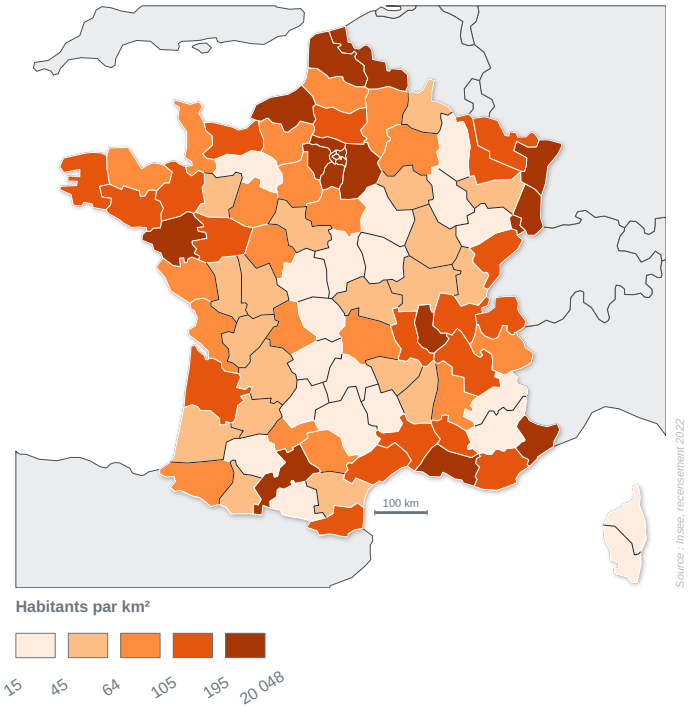


# Une gamme continue ou des classes

40 nuances




5 classes




- À gauche, presque une nuance par département. On devine les grandes villes, mais impossible de retrouver une valeur
- À droite, 5 classes. Chaque nuance renvoie à un intervalle de la légende
- La **discrétisation** découpe une série continue en classes

# Pourquoi des classes

## L'œil lit un ordre

La valeur (du clair au foncé) ne transmet qu'un ordre

L'œil distingue 8 à 9 paliers de valeur au plus sur une carte en aplats (Bertin)

## Au-delà

Il ne peut plus associer une couleur de la carte à une case de la légende

## Une perte choisie

Discrétiser réduit l'information pour qu'elle soit lisible

Le choix de la méthode décide de ce qui est perdu

# Des classes homogènes et bien séparées

Classes homogènes, variance intra-classe 0,43




Classes mal placées, variance intra-classe 3,64




Une bonne classe regroupe des valeurs proches. Deux classes voisines sont nettement différentes.

- Minimiser la **variance intra-classe**
- Maximiser la **variance inter-classe**
- La variance totale (13,06) est la somme des deux. Réduire l'une augmente l'autre

# Les règles de construction

Le découpage suit les mêmes règles qu'en statistique.

### Couvrir

Les classes vont du minimum au maximum de la série

### Sans trou

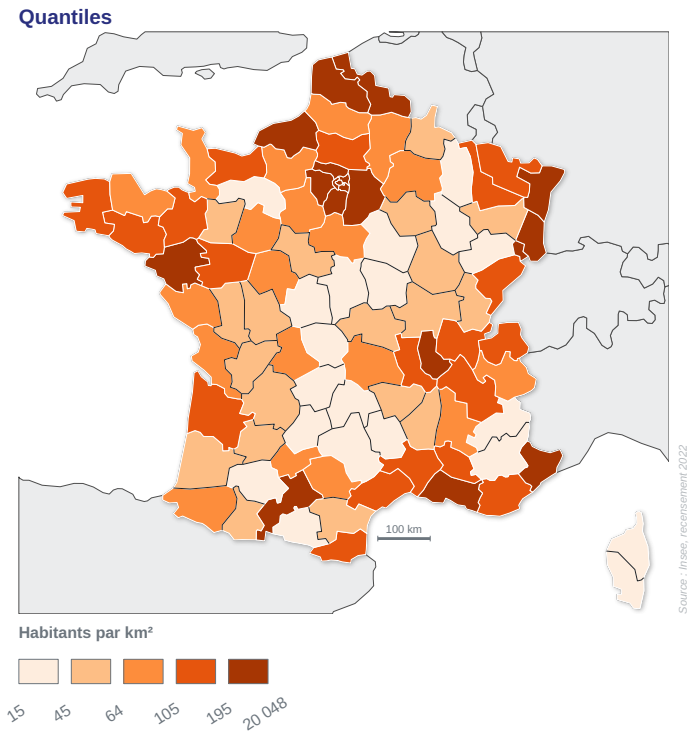
Elles sont contiguës

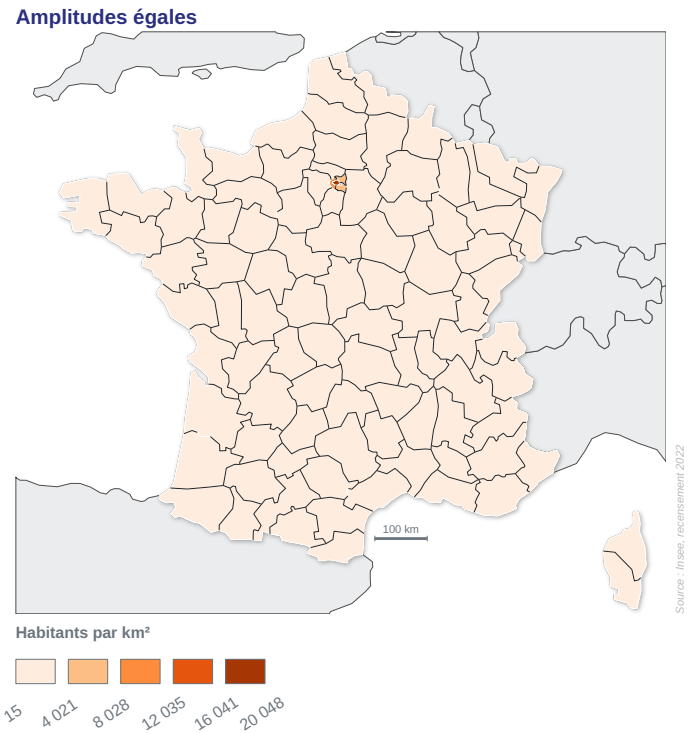
Une valeur appartient à une seule classe

### Sans vide

On évite les classes vides

# La méthode fait le message




- Mêmes données, 5 classes, deux méthodes
- Avec les quantiles, la France se partage entre départements ruraux clairs et départements urbains foncés
- Avec des amplitudes égales, 92 départements sur 96 tombent dans la première classe. Seuls Paris et la petite couronne ressortent
- Les deux cartes sont justes. Elles ne répondent pas à la même question

# 2 - Décrire la série

Regarder la distribution avant de choisir

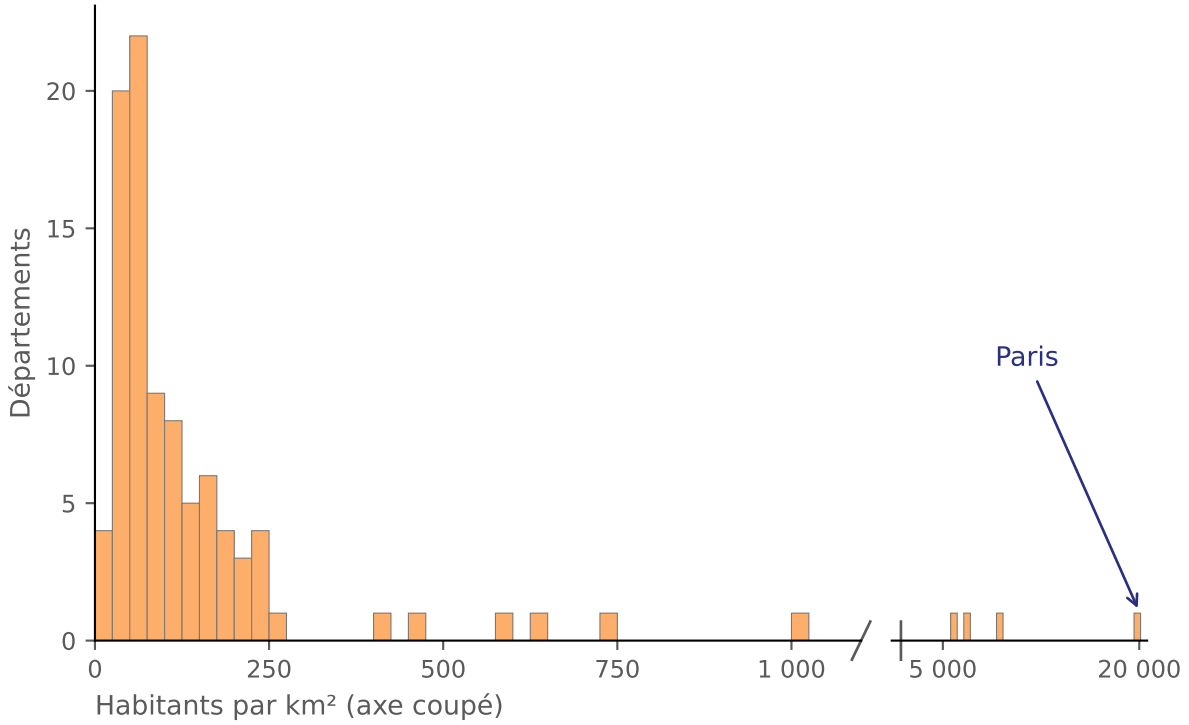
- Valeurs centrales et dispersion
- Une distribution étalée à droite



# Les questions à se poser

| | |
|---|---|
| **Le message** | Montrer la répartition statistique, ou des seuils qui ont un sens (zéro, une norme, une moyenne) ? |
| **La comparaison** | La carte sera-t-elle comparée à une autre date, ou à un autre indicateur ? |
| **Le public** | A-t-il besoin de classes simples et arrondies, quitte à perdre une partie de l'information ? |
| **La série** | Quelle forme a sa distribution ? Où sont les valeurs extrêmes ? |

# La série du fil rouge




| Indicateur | Valeur |
|---|---|
| Départements | 96 |
| Minimum (Lozère) | 15 |
| Médiane | 83 |
| Moyenne | 565 |
| Écart-type | 2 387 |
| Maximum (Paris) | 20 048 |
| Asymétrie | 6,5 |

# Une distribution étalée à droite

## Moyenne et médiane

La moyenne (565 hab./km$^2$) vaut près de sept fois la médiane (83)

Quelques valeurs très fortes la tirent vers le haut

## Répartition

La moitié des départements ont moins de 83 habitants par km$^2$, les trois quarts moins de 163

Paris (20 048), les Hauts-de-Seine (9 383) et la Seine-Saint-Denis (7 100) sont loin devant

## Conséquence

C'est une distribution dissymétrique à droite, fréquente pour les densités, les revenus ou les tailles de villes

Les méthodes ne placeront pas du tout les limites au même endroit

# 3 - Les méthodes

Cinq façons de placer les limites

- Quantiles et Q6
- Amplitudes égales
- Moyenne et écart-type
- Seuils naturels (Jenks)
- Les cinq cartes côte à côte



# % Les quantiles (effectifs égaux)

**Même nombre d'unités dans chaque classe. 96 départements ÷ 5 classes, 19 ou 20 par classe.**

## Avantages

Très simple à construire et à expliquer

Chaque couleur couvre la même part des unités

Applicable à toutes les distributions

Permet de comparer des rangs entre deux séries

## Limites

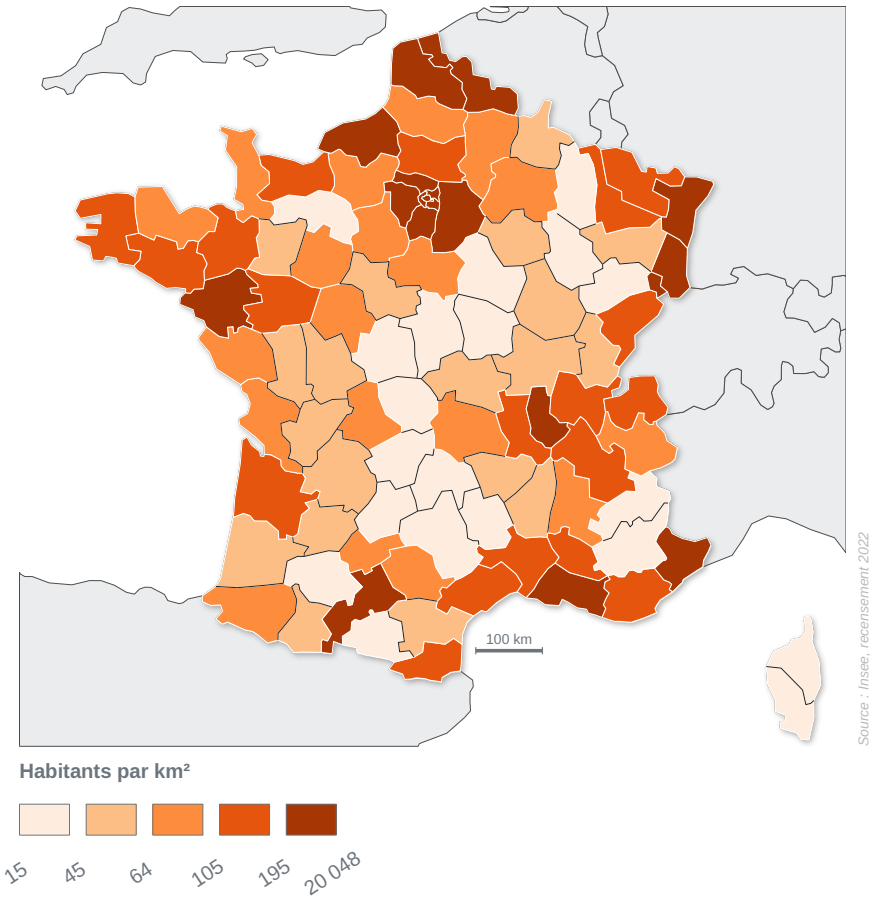
Ne suit pas la forme de la distribution

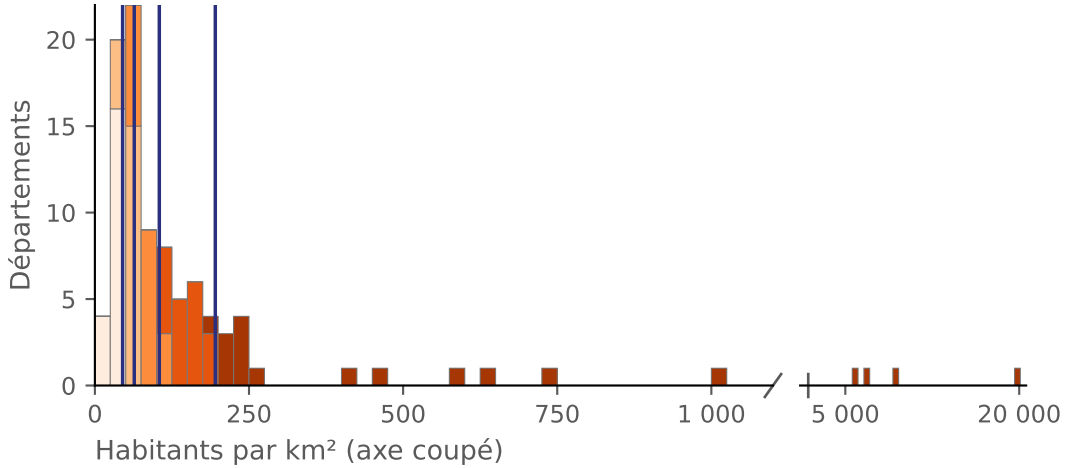
La dernière classe va de 195 à 20 048 hab./km$^2$

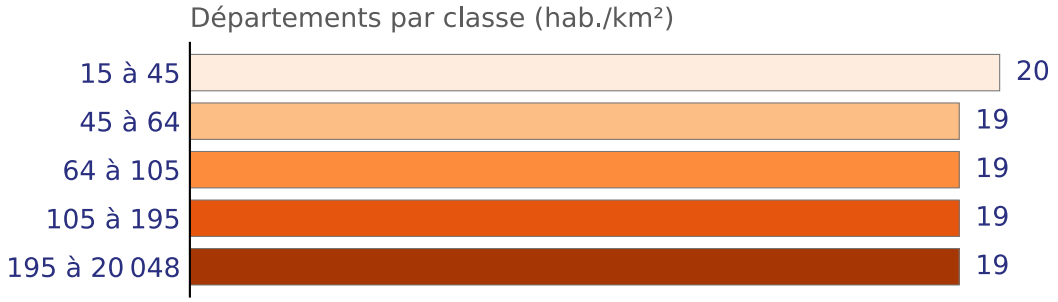
Le Territoire de Belfort y côtoie Paris

Deux valeurs proches peuvent tomber dans deux classes

# Les quantiles (effectifs égaux)



# Les quantiles, variante Q6

**Des quartiles dont les deux classes extrêmes sont isolées. 5 %, 20 %, 25 %, 25 %, 20 %, 5 % des unités.**

## Avantages

Simple et applicable à toutes les distributions

Met en évidence les extrêmes

Ici les 5 départements au-dessus de 800 hab./km² (Paris, la petite couronne, le Val-d'Oise) et les 5 sous 27

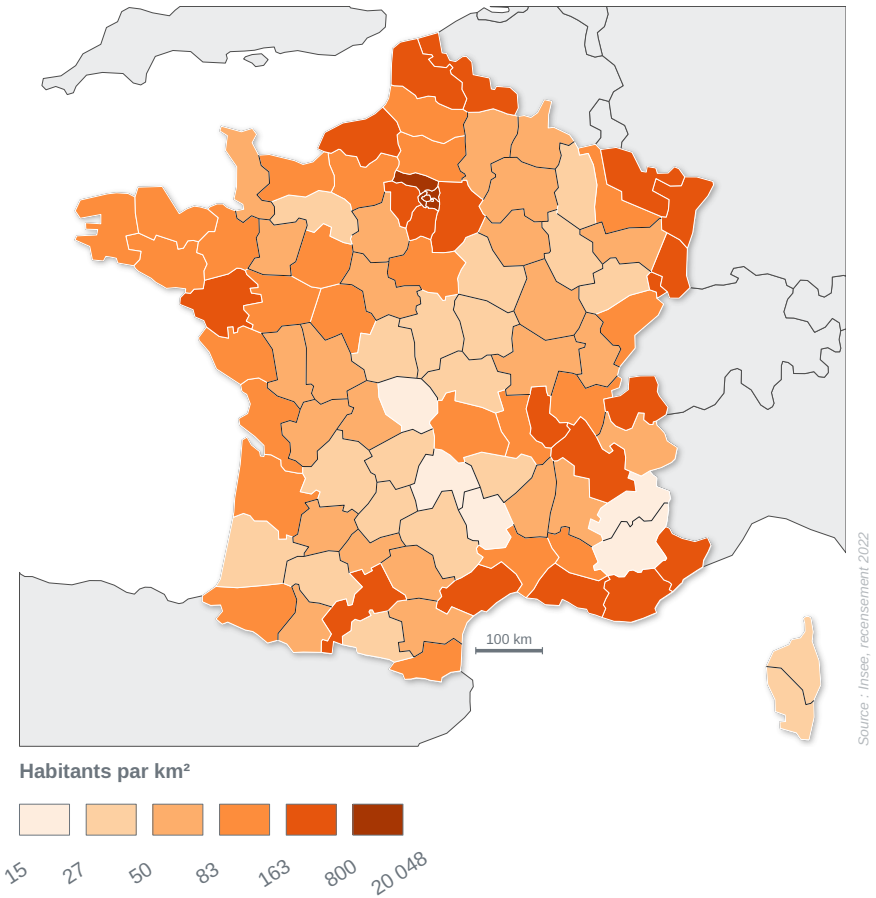
## Limites

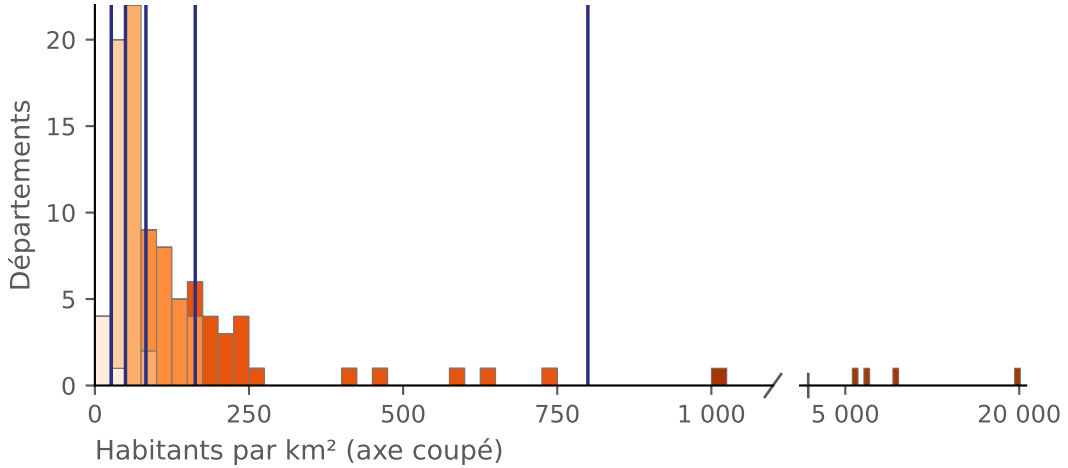
Toujours 6 classes

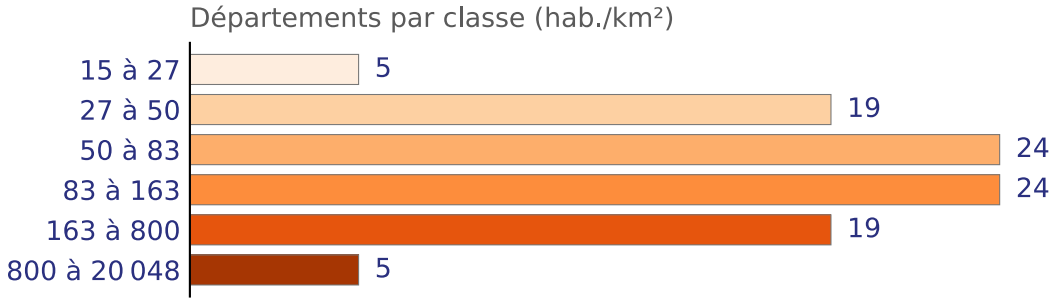
Moins connue du lecteur

Proposée par le logiciel Philcarto

# Les quantiles, variante Q6



# = Les amplitudes égales

**Des classes de même largeur. (maximum − minimum) ÷ 5 = 4 007 hab./km².**

## Avantages

Très simple à comprendre

Adaptée à une distribution uniforme

Des limites rondes parlent au grand public

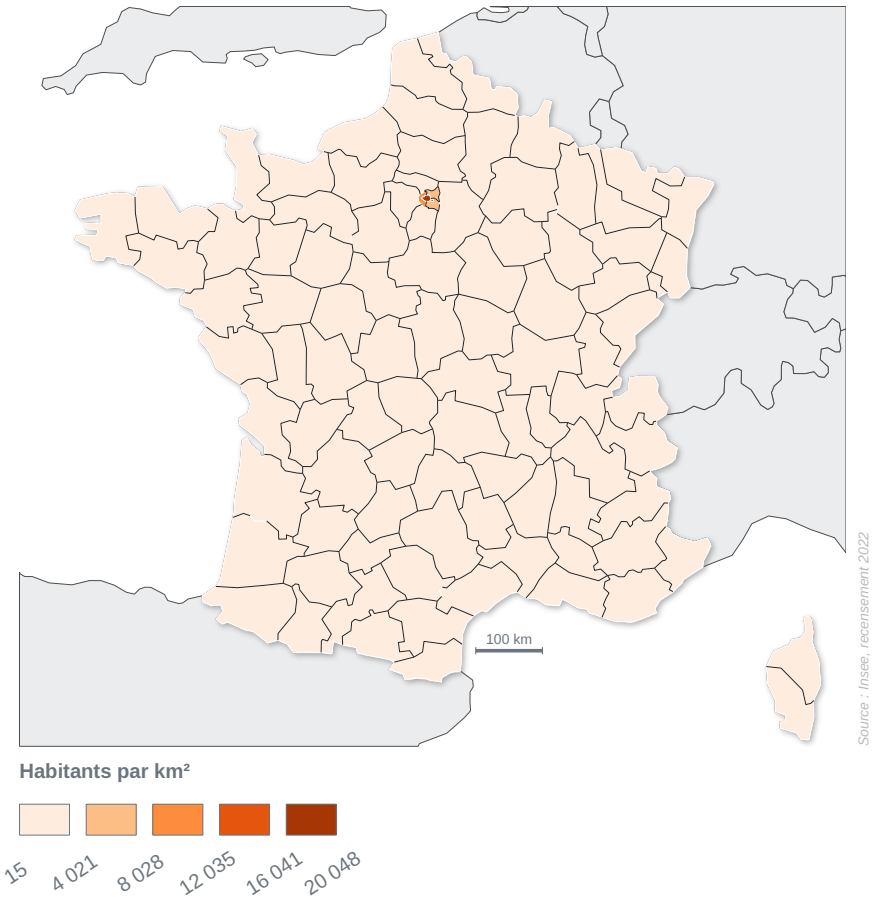
## Limites

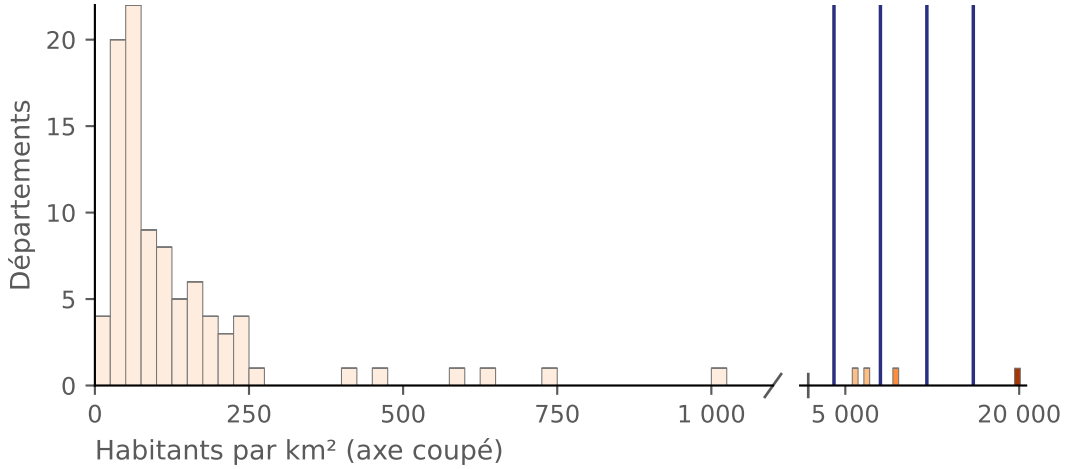
Très mal adaptée à une série étalée à droite

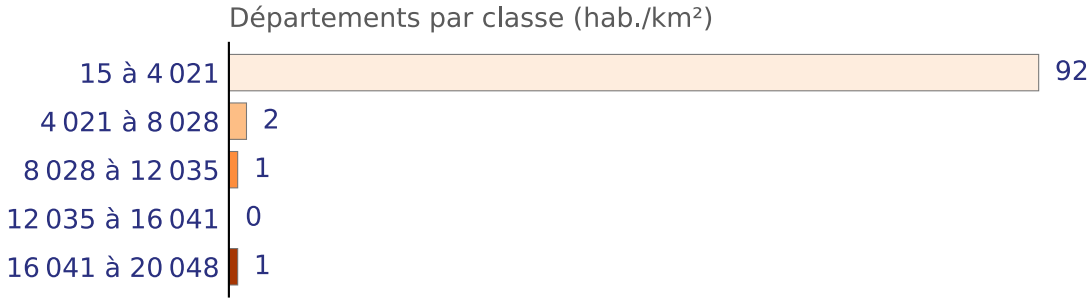
92 départements sur 96 dans la première classe, une classe vide

Paris suffit à fixer toutes les limites

# Les amplitudes égales



# La moyenne et l'écart-type

**La moyenne au centre de la classe centrale, des classes d'un écart-type (σ) de large. Limites à moyenne ± 0,5σ et ± 1,5σ.**

## Avantages

Montre l'écart à la moyenne

La classe centrale est neutre, les classes extrêmes isolent les valeurs « anormales »

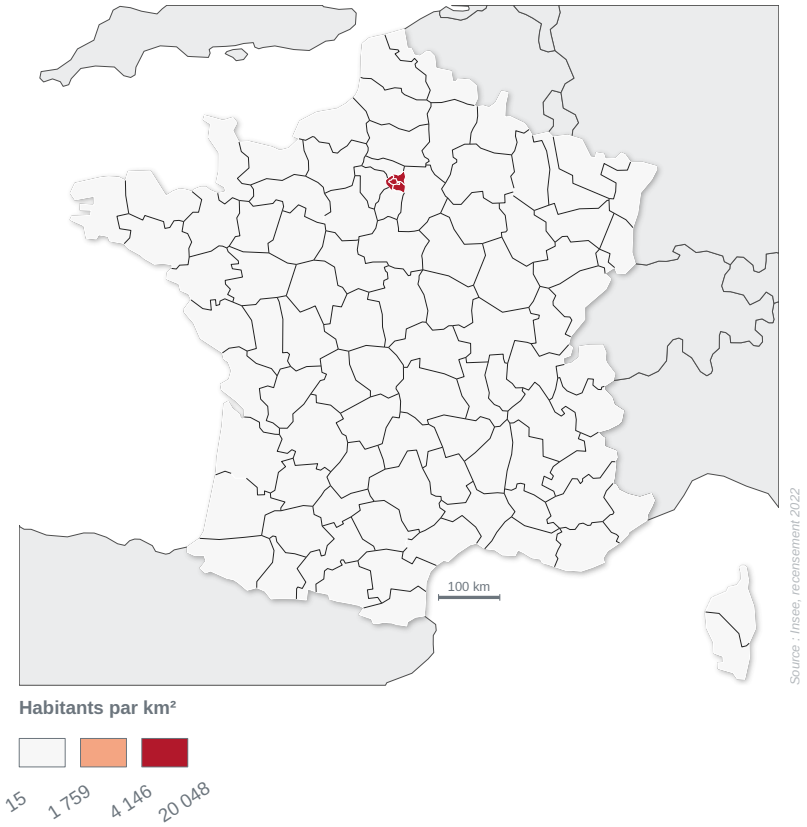
Permet de comparer deux séries normales de moyennes et d'écarts-types proches

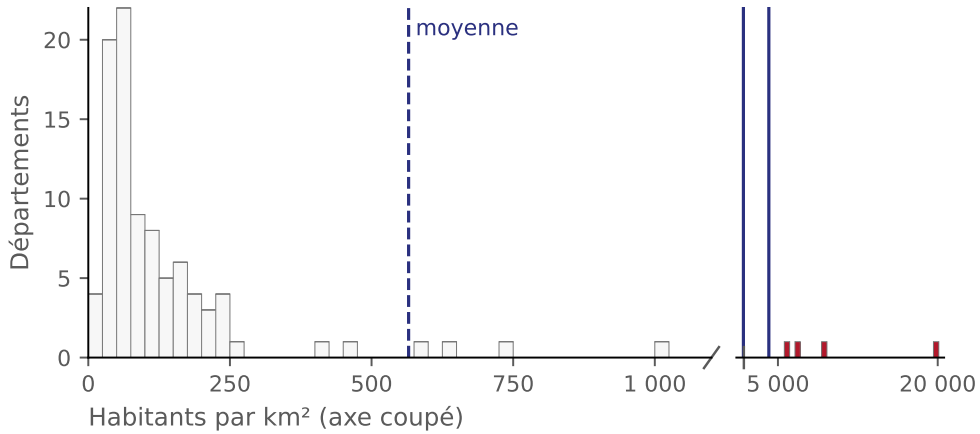
## Limites

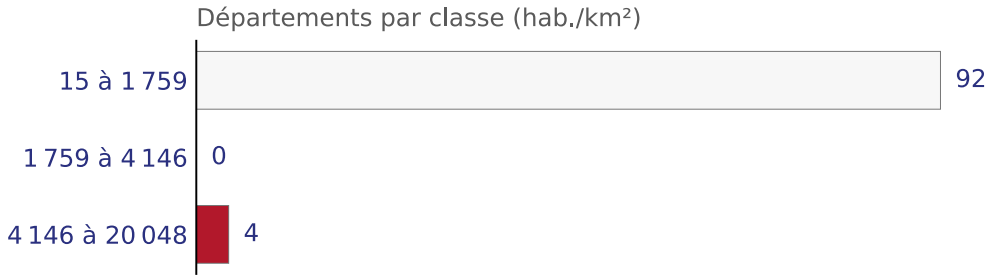
Réservée aux distributions normales, symétriques autour de la moyenne

Sur une série étalée à droite, il faut d'abord la transformer

# Moyenne et écart-type, sur la densité brute

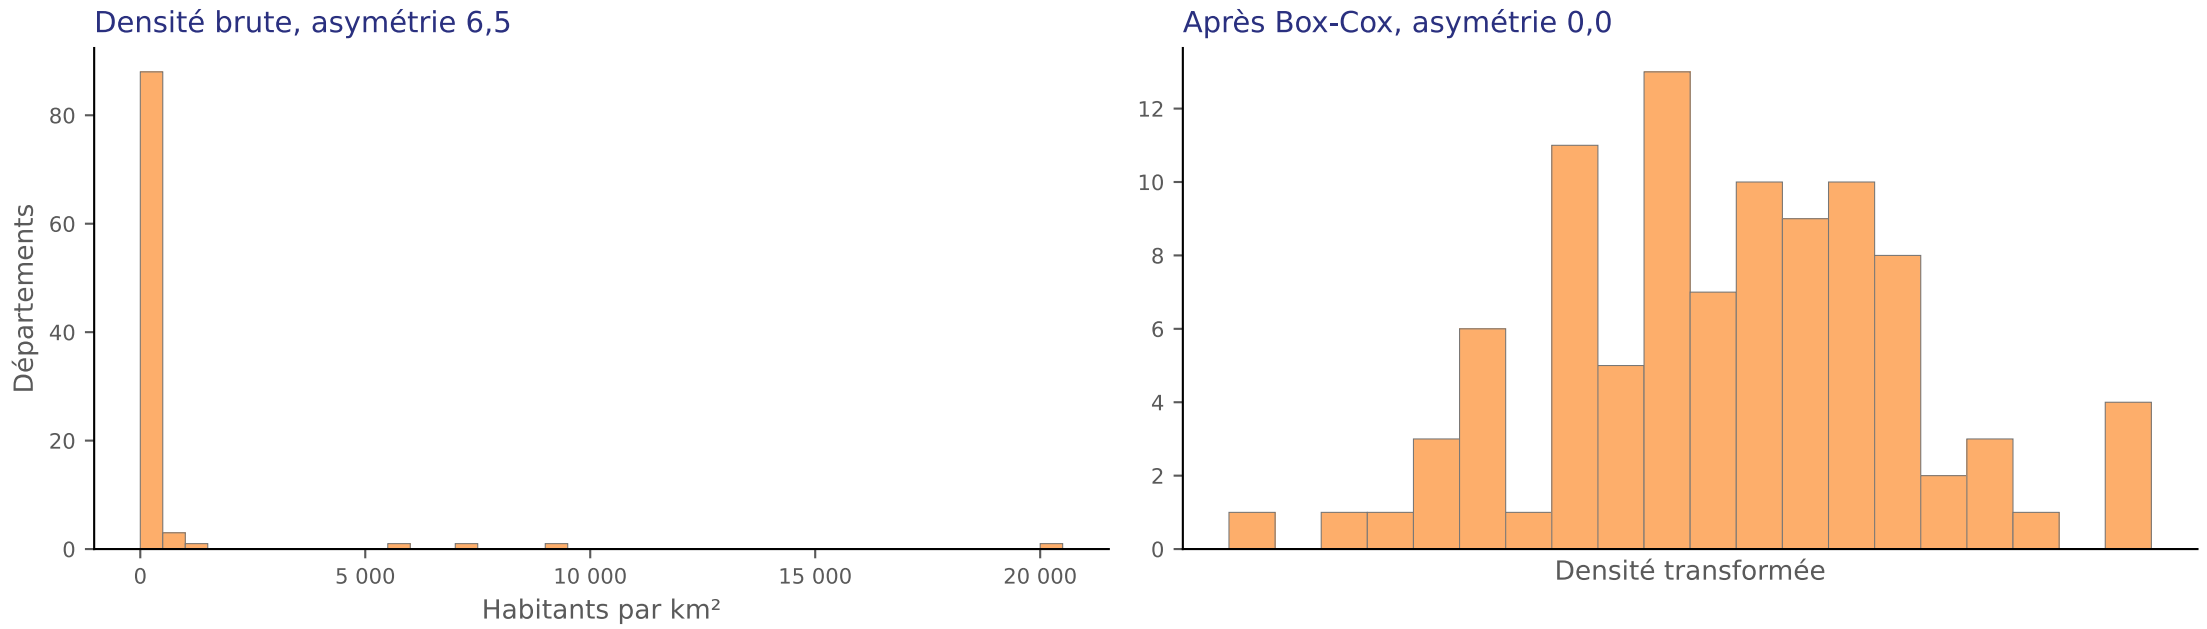


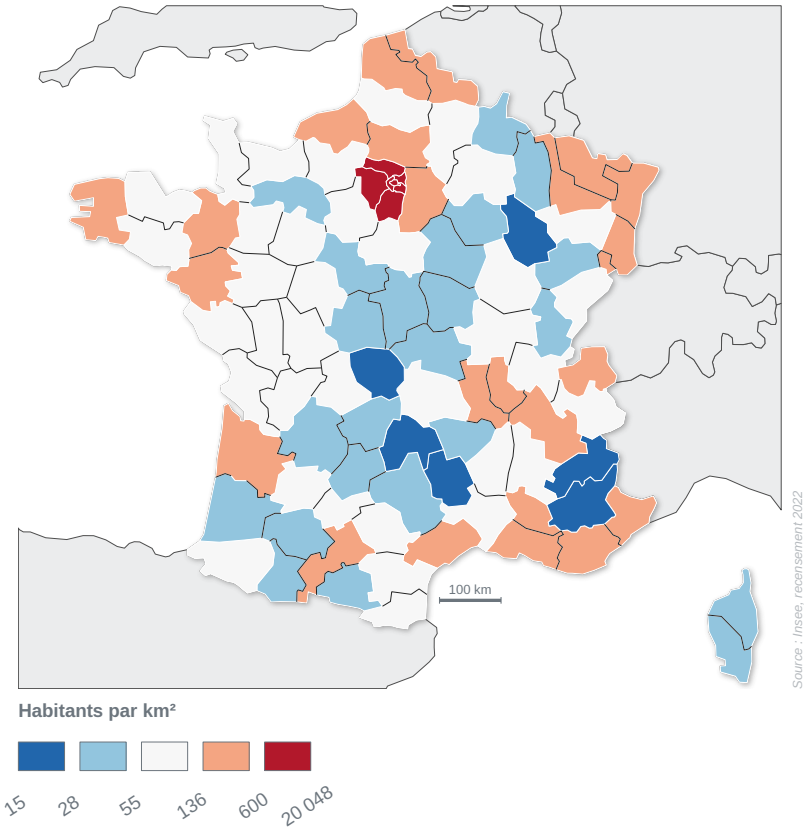

Moyenne 565, écart-type 2 387. La moyenne − 0,5σ est négative, la moyenne − 1,5σ aussi. Il ne reste que 3 classes, dont une de 92 départements.

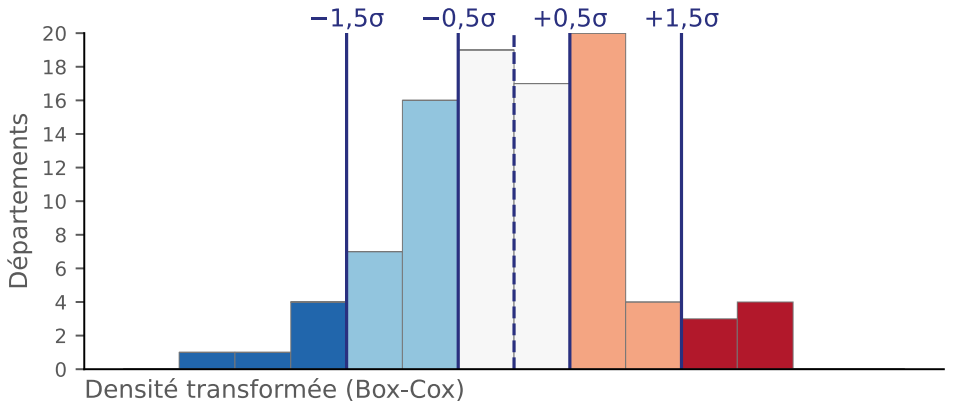
# Rendre la série normale

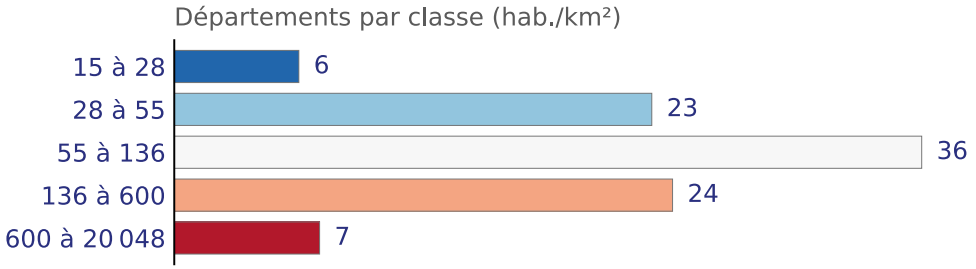



- La transformation de Box-Cox élève la densité à une puissance λ, choisie pour rendre la série la plus proche d'une loi normale. Ici λ = −0,42
- La série transformée est symétrique. La moyenne et l'écart-type y retrouvent un sens
- On calcule les limites sur la série transformée, puis on les ramène en hab./km² par la transformation inverse

# Moyenne et écart-type, après transformation




Les limites calculées sur la série transformée valent 28, 55, 136, 600 hab./km². La classe centrale, neutre, regroupe les départements proches de la moyenne.

# Les seuils naturels (Jenks)

**Un algorithme cherche les limites qui minimisent la variance intra-classe (Jenks, 1967 ; Fisher, 1958).**

## Avantages

Suit au mieux la forme de la distribution

Regroupe les valeurs semblables et isole les extrêmes (Paris seul dans sa classe)

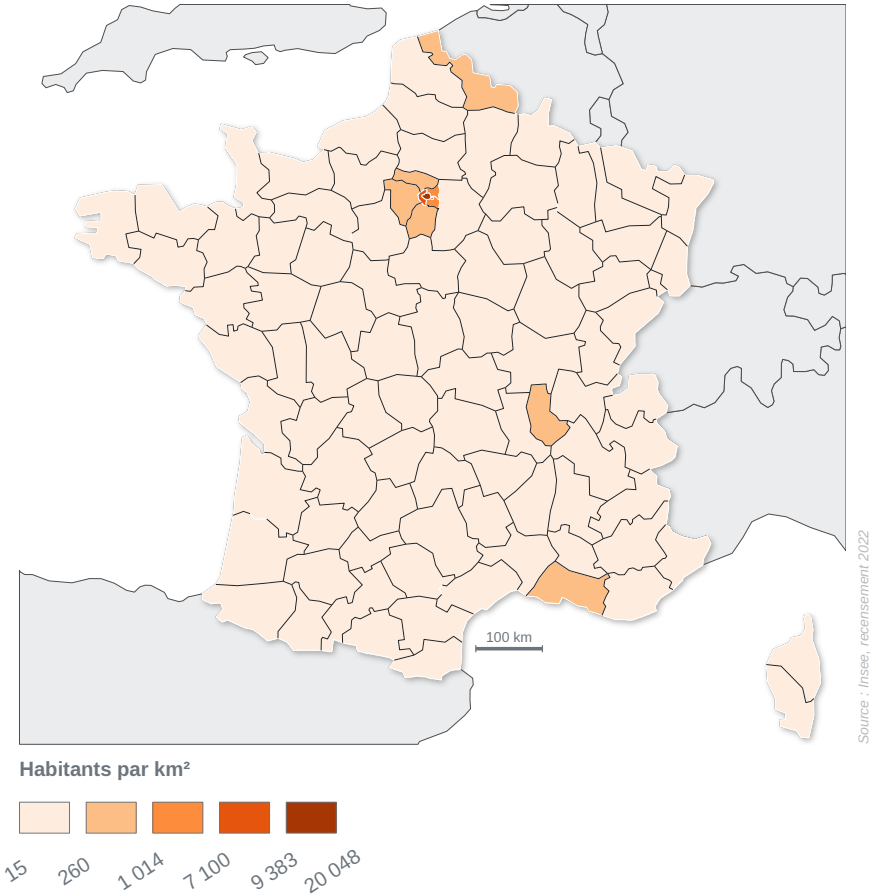
## Limites

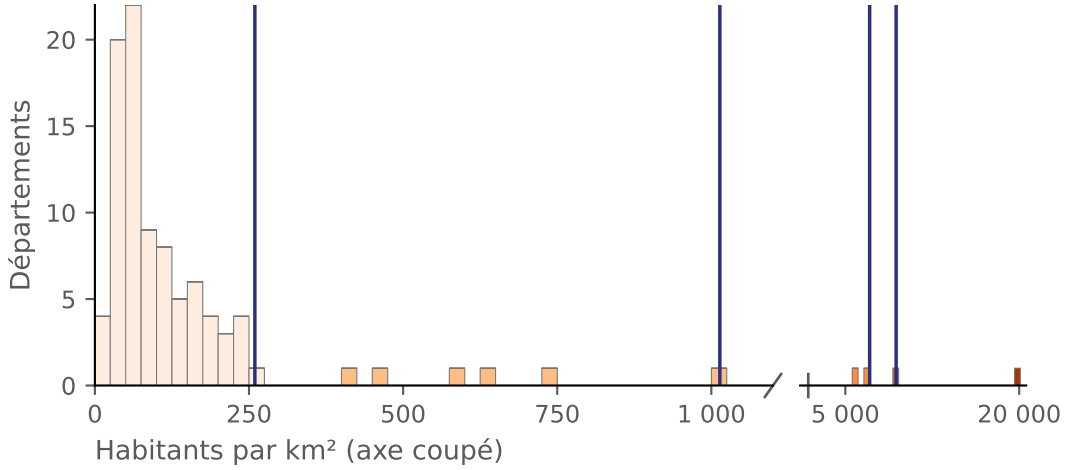
Sur une série très étalée, l'algorithme consacre presque toutes les classes aux valeurs fortes

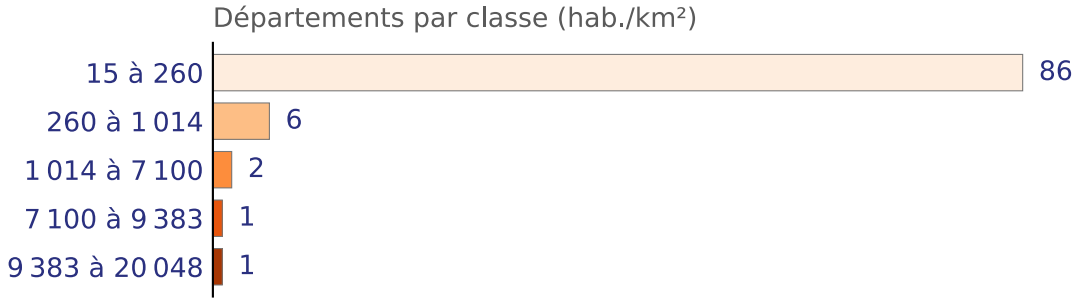
86 départements partagent la première

Limites propres à chaque série, rarement rondes

# Les seuils naturels (Jenks)

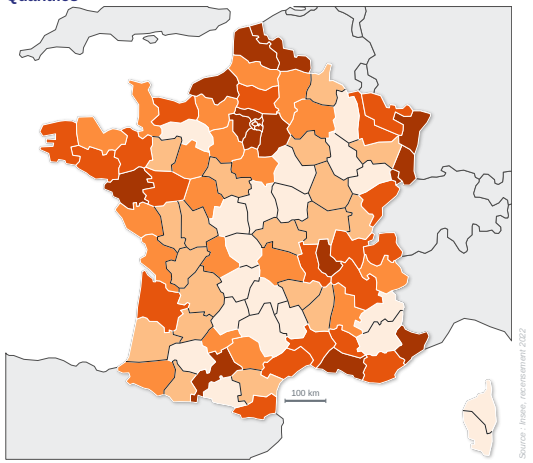


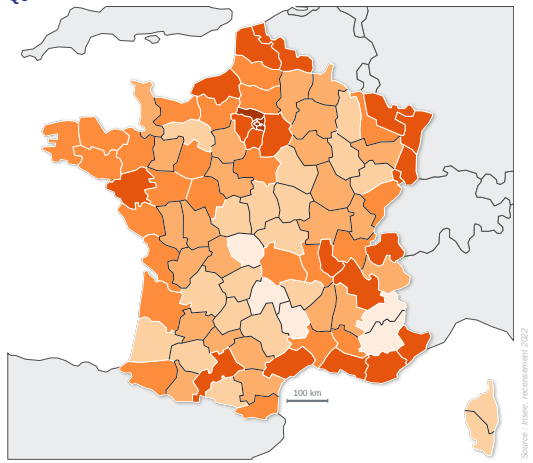



# Cinq méthodes, cinq cartes

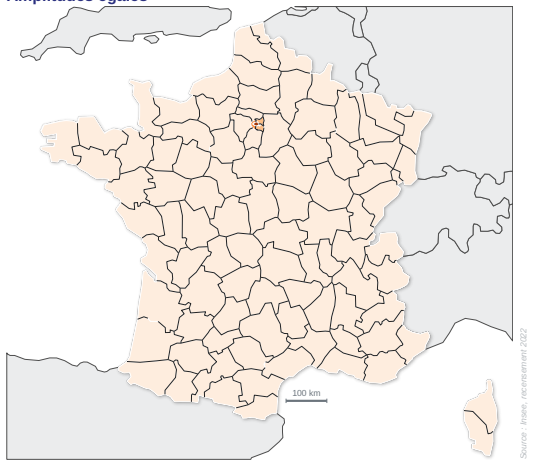
Quantiles



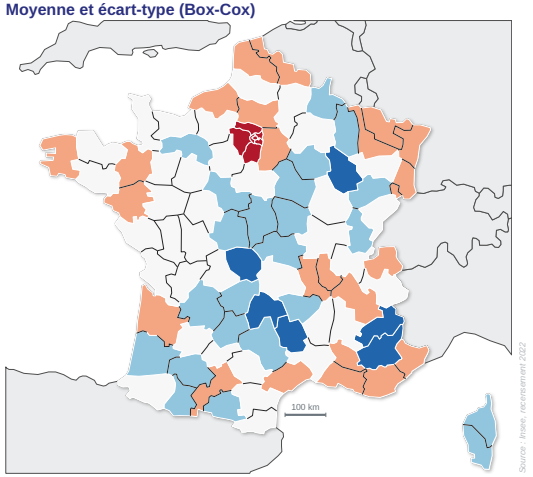

Q6



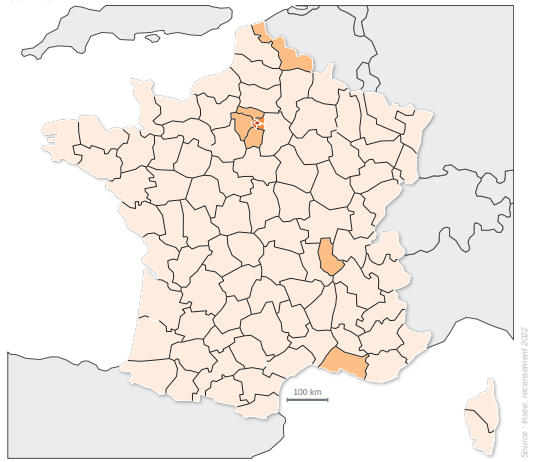

Amplitudes égales




Moyenne et écart-type (Box-Cox)




Jenks




- Amplitudes égales et Jenks ne montrent que l'Île-de-France
- Quantiles, Q6 et écart-type (après transformation) font apparaître les métropoles et la « diagonale du vide »
- La méthode se choisit d'après le message et la distribution

# 4 - Questions fréquentes

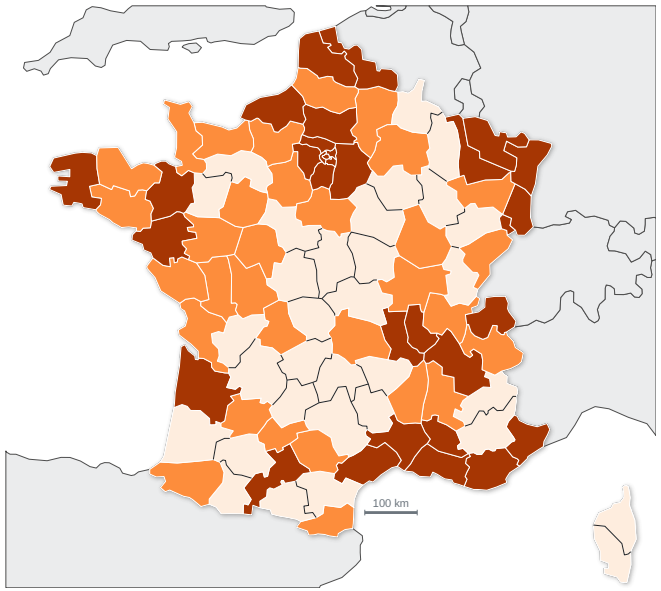
Classes, arrondis, comparaisons

- Combien de classes ?
- Faut-il arrondir ?
- Comparer deux cartes

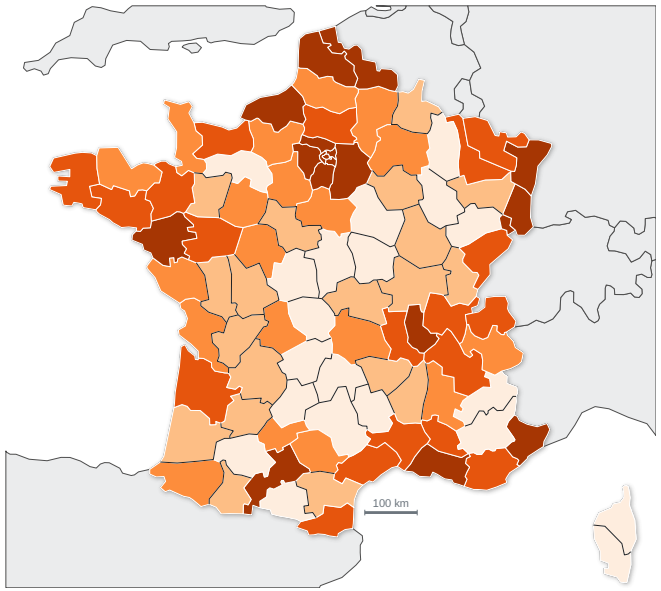


# Combien de classes ?

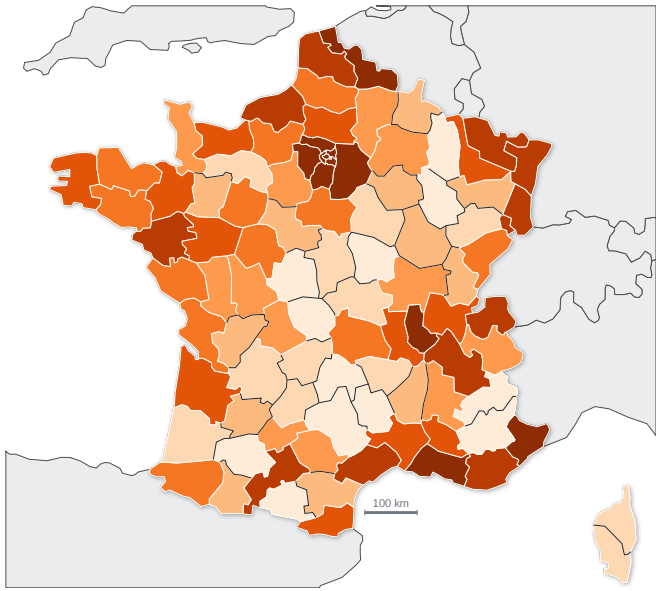
3 classes




5 classes




8 classes




- Quantiles dans les trois cas. Avec 3 classes, l'information spatiale est trop pauvre. Avec 8, les oranges voisins se confondent
- En cartographie, 4 à 7 classes. 5 classes est un bon point de départ
- Une règle statistique (Sturges, $1 + \log_2(n)$) donne 7 classes pour 96 départements, trop pour une carte

# Arrondir les limites

| Limites calculées (quantiles) | Limites arrondies |
|---|---|
| 14,79 à 44,95 | 15 à 45 |
| 44,95 à 63,87 | 45 à 65 |
| 63,87 à 104,51 | 65 à 100 |
| 104,51 à 195,32 | 100 à 200 |
| 195,32 à 20048,14 | 200 à 20 050 |

- Pour une densité, des entiers suffisent. Des valeurs rondes (100, 200) se retiennent mieux
- Arrondir **avant** la mise en page, dans le logiciel de cartographie. Une unité peut changer de classe
- Les arrondis ne doivent pas déformer la méthode
- Le minimum et le maximum réels restent visibles

# Comparer deux cartes

## Comparaison absolue

Des données de même nature (même indicateur, deux dates ou deux territoires)

Mêmes limites de classes sur les deux cartes

Une couleur = un même intervalle de valeurs

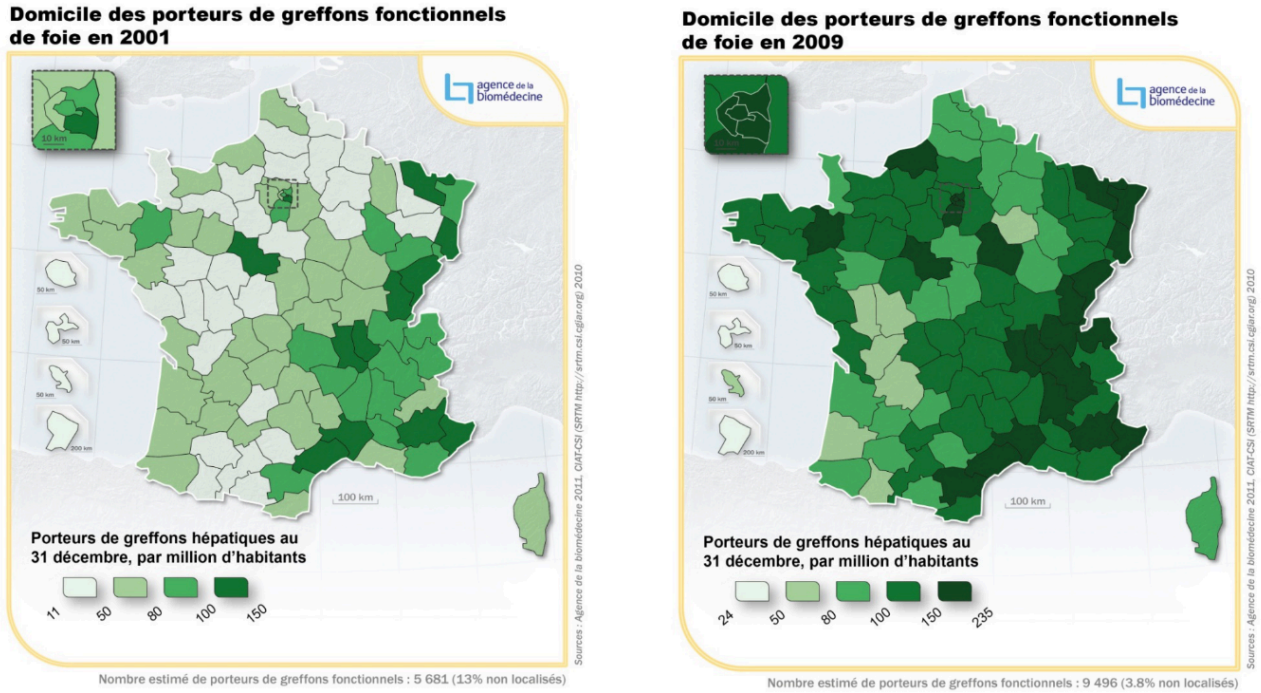
## Comparaison relative

Des données de nature différente

Mêmes fréquences dans les classes (quantiles, Q6)

Une couleur = une même position dans la série

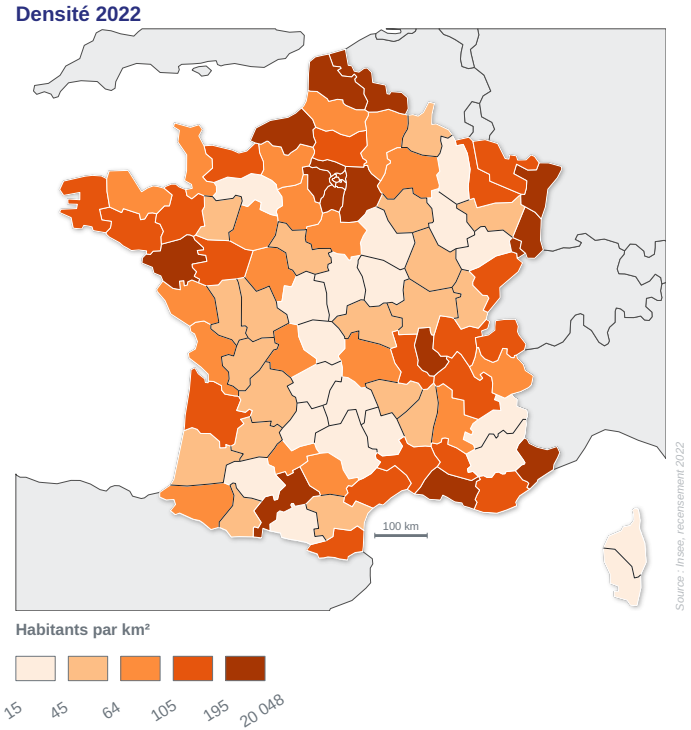
# = Comparaison absolue, deux dates

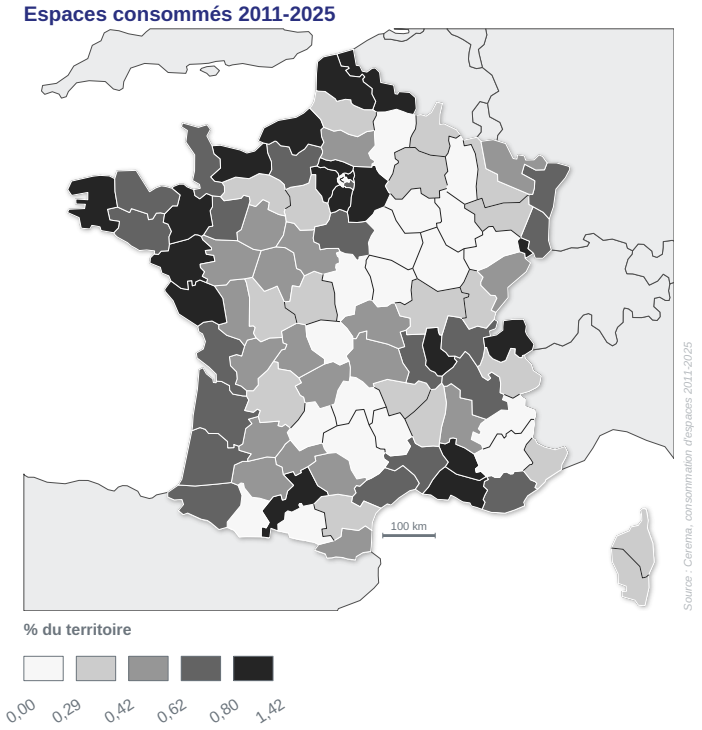



Agence de la biomédecine, 2011

- Porteurs d'un greffon de foie fonctionnel, par million d'habitants, en 2001 et en 2009
- Limites de Jenks calculées en 2001 (50, 80, 100), reprises en 2009
- Le minimum est ajusté (11 en 2001, 24 en 2009)
- Une classe est ajoutée en 2009 (150 à 235)
- Un même vert désigne la même valeur. L'augmentation se lit d'une carte à l'autre

# Comparaison relative, deux indicateurs




- Deux mesures de la pression urbaine, sans unité commune. Quintiles sur chaque carte
- Une couleur foncée désigne les 20 % de départements aux valeurs les plus fortes
- 13 départements sont dans le dernier quintile des deux séries (Nord, Rhône, Haute-Garonne, grande couronne...). 14 sont dans le premier des deux
- Paris et les Hauts-de-Seine, très denses, consomment peu. Il ne reste presque plus d'espace à bâtir

# Conclusion

Choisir et justifier

- Quelle méthode pour quel besoin
- Ce qu'il faut retenir



# Quelle méthode pour quel besoin

### Éviter le soupçon

Quantiles, ou Q6 pour garder les extrêmes

Les classes ne suivent pas la distribution

### Suivre la distribution

Jenks

La carte ne se compare pas à une autre sans reprendre ses limites

### Le grand public

Amplitudes égales et limites rondes, si la distribution s'y prête

Garder le vrai minimum et le vrai maximum

### Montrer les écarts

Moyenne et écart-type

Sur une série normale (ou rendue normale)

### Comparer

Mêmes limites pour des données de même nature

Mêmes fréquences (quantiles) sinon

### Dans tous les cas

Indiquer la méthode dans la légende ou en note

La carte doit pouvoir être refaite

# Ce qu'il faut retenir

| | |
|---|---|
| **Pourquoi** | Un taux se discrétise, car l'œil ne lit qu'un ordre, sur 8 à 9 paliers au plus |
| **Avant** | Décrire la série d'abord (forme, valeurs centrales, dispersion, extrêmes) |
| **Choisir** | La méthode dépend du message, du public et de la comparaison voulue<br>Les classes peuvent être ajustées à la main si c'est justifié (autour de zéro, d'une norme) |
| **Présenter** | Arrondir les limites et garder le vrai minimum et le vrai maximum<br>Indiquer la méthode dans la légende ou en note, pour que la carte puisse être refaite |

# Bibliographie


**Fisher, W. D. (1958).** On grouping for maximum homogeneity. *Journal of the American Statistical Association*, 53(284), 789-798.

**Box, G. E. P., Cox, D. R. (1964).** An analysis of transformations. *Journal of the Royal Statistical Society, Series B*, 26(2), 211-252.

**Jenks, G. F. (1967).** The data model concept in statistical mapping. *International Yearbook of Cartography*, 7, 186-190.

**Tobler, W. R. (1973).** Choropleth maps without class intervals? *Geographical Analysis*, 5(3), 262-265.

**Brewer, C. A., Pickle, L. (2002).** Evaluation of methods for classifying epidemiological data on choropleth maps in series. *Annals of the Association of American Geographers*, 92(4), 662-681.

**Zanin, C., Trémélo, M.-L. (2003).** *Savoir faire une carte.* Belin, Paris.

**Lambert, N., Zanin, C. (2016).** *Manuel de cartographie. Principes, méthodes, applications.* Armand Colin, Paris.

**Béguin, M., Pumain, D. (2017).** *La représentation des données géographiques. Statistique et cartographie*, 4e éd. Armand Colin, Paris.

**Cerema (2025).** *Consommation d'espaces naturels, agricoles et forestiers du 1er janvier 2011 au 1er janvier 2025.* Données communales, data.gouv.fr.

# TD - Le choix des classes

Feuillus et conifères en France

- La commande
- Quatre groupes, quatre méthodes
- Ce qu'il faut rendre



# Consigne

Le groupe de travail sur la forêt (TD précédent) veut comparer la part des conifères et celle des feuillus dans les forêts françaises.

- Deux cartes choroplèthes, colonnes p_feuillus et p_conifere du fichier DEP_FORET_3857.geojson
- Quatre groupes, une méthode tirée au sort par groupe

| Groupe 1 | Groupe 2 | Groupe 3 | Groupe 4 |
| --- | --- | --- | --- |
| Quantiles | Q6 | Amplitudes égales | Seuils naturels (Jenks) |

# Rendu

Chaque groupe présente en quelques minutes.

- La distribution des deux séries (histogramme, valeurs centrales, dispersion)
- Les avantages et les limites de sa méthode sur ces données
- Les deux cartes, mises en page
- Les arguments en faveur de sa méthode puis la manière de comparer les deux cartes (absolue ou relative)