

COURS MAUP

MODIFIABLE AREAL UNIT

PROBLEM

M2 IGAST

🎯 OBJECTIFS DU TD

Ce cours a pour objectif de vous sensibiliser au Modifiable Areal Unit Problem (MAUP) et à ses implications pour l'analyse spatiale.

Il vous permettra de comprendre comment le choix des unités spatiales peut influencer les résultats de l'analyse et d'apprendre à identifier et à atténuer les effets du **MAUP**.

1 - LE MAUP

COMPRENDRE LE PROBLÈME

1.1 - DÉFINITION DU MAUP

Le **MAUP (Modifiable Areal Unit Problem)** est un biais statistique qui peut influencer les résultats en analyse spatiale.

Il survient lorsque des mesures ponctuelles de phénomènes spatiaux sont agrégées en unités spatiales (comme des régions ou des maillages abstraits) pour calculer des **valeurs résumées** telles que des taux ou des proportions.

Ces valeurs sont influencées à la fois par la **forme** et par l'**échelle** de l'unité d'agrégation.

1.1 - DÉFINITION DU MAUP

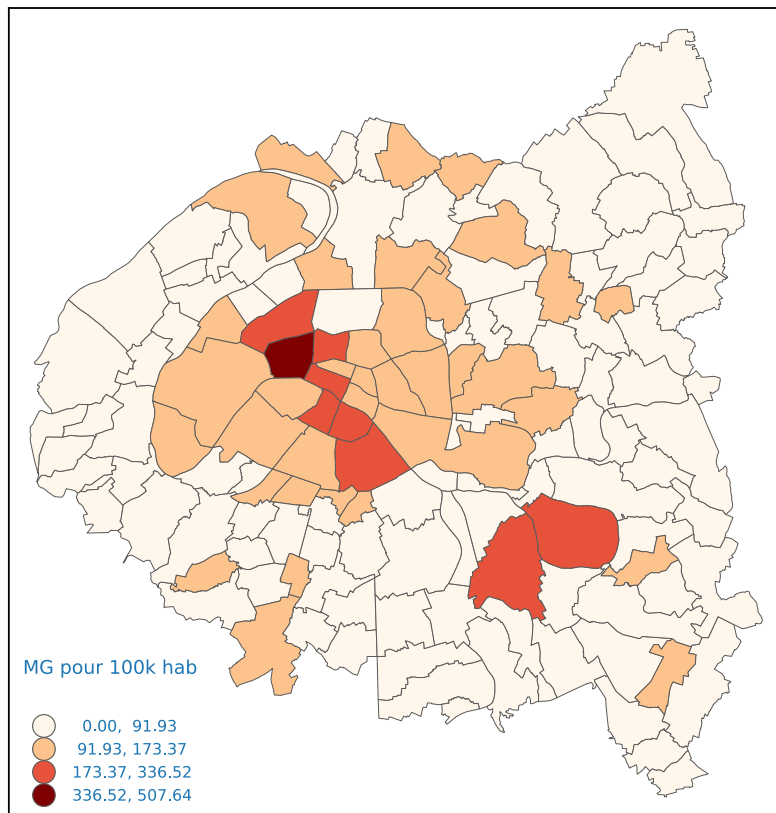
Les conclusions que vous tirez de l'analyse de données spatiales peuvent varier en fonction de la **taille**, de la **forme** et de la **configuration** des unités géographiques que vous utilisez.

Ce problème peut conduire à des **interprétations erronées** des données et à des conclusions inexactes.

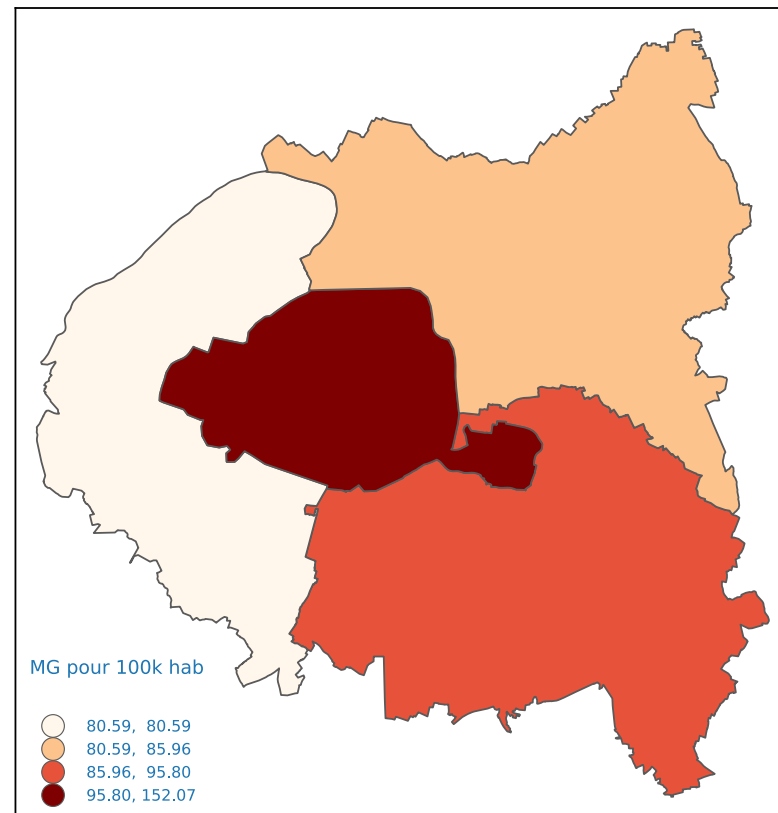
Les résultats de vos études dépendront du découpage spatial choisi !

1.1 - EXEMPLE : DENSITÉ DE MÉDECINS GÉNÉRALISTES EN IDF

Niveau Communal



Niveau Départemental



Niveau communal : Forte variabilité spatiale de la densité entre communes. **Niveau départemental** : Lissage des variations par agrégation. **Constat** : Distribution spatiale et variabilité changent avec l'échelle.

1.1 - CONSÉQUENCES DU MAUP

BIAIS DANS LES INTERPRÉTATIONS

Résultats variant selon le mode d'agrégation géographique

BIAIS DANS LES ÉTUDES

Corrélation réelle masquée

Association artificielle créée

GÉNÉRALISATION LIMITÉE

Résultats non généralisables à d'autres zones avec limites différentes

IMPACT SUR LES DÉCISIONS

Décisions biaisées basées sur données agrégées

1.2 - LES DEUX MANIFESTATIONS DU MAUP

Le MAUP survient lorsque les données sont agrégées géographiquement.

Il se manifeste par **deux effets principaux** :

1. **L'effet de zonage** → forme des unités
2. **L'effet d'échelle** → taille des unités


1.2 - EFFET DE ZONAGE

Il s'agit de la variation des statistiques causée par le regroupement des données en **configurations différentes mais à la même échelle**.


Exemple : deux maillages différents pour la même zone avec une population répartie régulièrement dans l'espace. Les valeurs agrégées varient selon le découpage choisi.

Même échelle, formes différentes = résultats différents !


Grille régulière + points




Maillage administratif + points



Agrégation grille



Agrégation administrative



✖ 1.2 - EFFET D'ÉCHELLE

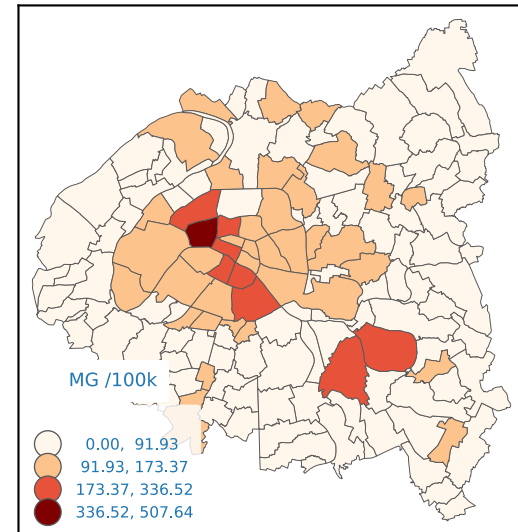
L'effet d'échelle provoque une variation des résultats entre **niveaux d'agrégation différents**.

Exemple de la densité de médecins à Paris PC :


- Niveau communal : forte variabilité.
- Niveau départemental : lissage des variations.

Échelles différentes = résultats différents !

Communal (n=143)



Départemental (n=8)




1.2 - EXEMPLE DES DEUX EFFETS

Population générale

500	100	700
200	400	100
300	600	200


Effet de zonage - configuration 1




Population pauvre

25	40	100
100	80	6
30	150	85


Effet de zonage - configuration 2



Taux de pauvreté (maillage d'origine)



Effet d'échelle - 3 lignes d'agrégat



1.3 - EXEMPLE SYNTHÉTIQUE


500 observations distribuées
aléatoirement **Deux variables**
corrélées ($R\ 0.70$)

Trois maillages à comparer :


- Grille 10km (25 zones)
- Grille 20km (9 zones)
- Maillage administratif (6 zones)

→ Mêmes données, agrégations
différentes


Grille 10km - Variable 1




Grille 10km - Variable 2





Grille 20km - Variable 1



Grille 20km - Variable 2



Maillage administratif - Variable 1Maillage administratif - Variable 2

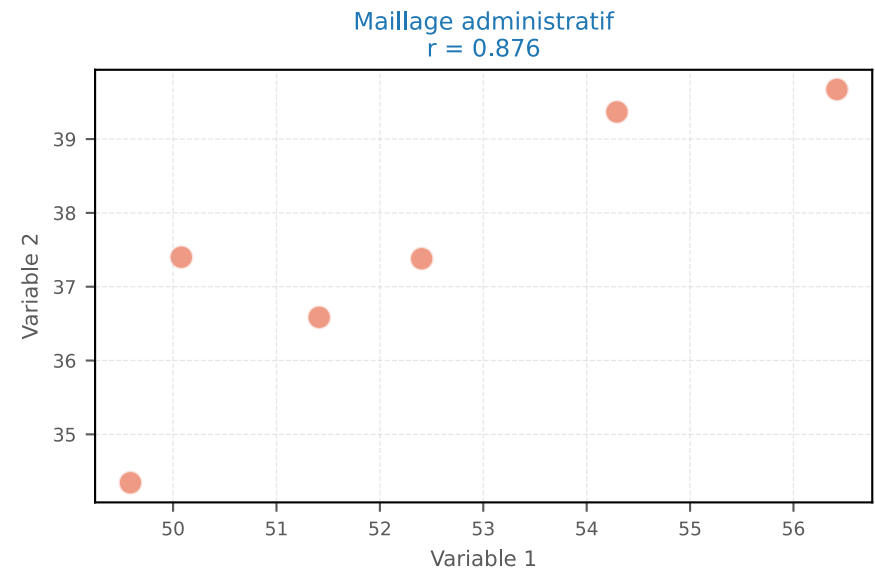



1.3 - IMPACT DU ZONAGE

Même ensemble de données,
zonages différents :

- Grille 10km : $r = 0.845$
- Maillage administratif : $r = 0.876$

**La forme du zonage modifie la
corrélation observée !**



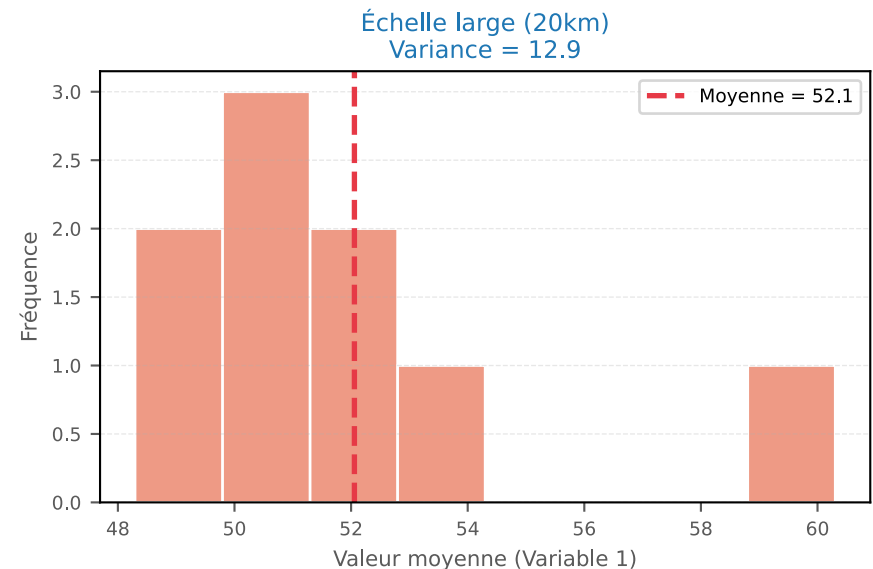

❖ 1.3 - IMPACT DE L'ÉCHELLE

Même ensemble de données, même forme (grille), **échelles différentes** :

- Échelle fine (10km) : 25 zones, variance = **18.3**
- Échelle large (20km) : 9 zones, variance = **12.9**

L'agrégation à une échelle plus large réduit la variance !

→ Effet de lissage spatial : les valeurs extrêmes sont moyennées



1.4 - EXEMPLE : PARADOXE DE SIMPSON

	Employés	Chômeurs	Total	Chômeurs %
Zone A				
Jeunes	81	9	90	10%
Vieux	9	1	10	10%
Total	90	10	100	10%
Zone B				
Jeunes	40	10	50	20%
Vieux	40	10	50	20%
Total	80	20	100	20%
Zone A+B				
Jeunes	121	19	140	13.6%
Vieux	49	11	60	18.3%
Total	170	30	200	15%

Données de départ :

- Zone A : 10% de chômage (tous âges)
- Zone B : 20% de chômage (tous âges)

Après agrégation (A+B) :

- Jeunes : 13,6% (\neq 15%)
- Vieux : 18,3% (\neq 15%)

Paradoxe : L'agrégation crée des différences qui n'existaient pas dans les données initiales !

2.3.1 - OBSERVATIONS

- Les zones A et B ont chacune une population totale de 100 personnes.
- Dans la zone A, 10% de jeunes et 10% de vieux sont au chômage.
- Dans la zone B, 20% de jeunes et 20% de vieux sont au chômage.
- **La part des chômeurs est donc la même dans les deux zones.**

Si l'on combine les zones A et B, on pourrait s'attendre à ce que le taux de chômage global soit de **15%** pour les deux groupes.

Mais ce n'est pas le cas !

2.3.2 - LE BIAIS OBSERVÉ

Résultats observés en combinant A+B :

- Le taux de chômage combiné pour les jeunes est de **13,6%** (au lieu de 15%)
- Le taux de chômage combiné pour les vieux est de **18,3%** (au lieu de 15%)

Ce résultat inattendu est dû à la différence de la taille des populations de chaque groupe dans les zones A et B :

- La zone A a une population **jeunes beaucoup plus importante** que la population âgée
- La zone B a des populations jeunes et âgées **égales**

En combinant les zones, le taux de chômage global est davantage influencé par la zone A, qui a une population jeune plus importante.

! 2.3.2 - CONSÉQUENCE DU BIAIS

Cela crée un biais qui donne l'impression que le taux de chômage est plus faible pour les jeunes que pour les vieux

Le choix de l'unité spatiale d'agrégation (zone A, zone B ou A+B) a un impact direct sur les statistiques calculées et peut conduire à des conclusions erronées.

Les statistiques agrégées peuvent raconter une histoire complètement différente de la réalité.

2.4 - EXEMPLE : LE GERRYMANDERING

Le **Gerrymandering** est une pratique qui consiste à manipuler les frontières des circonscriptions électorales afin de favoriser un parti politique ou un groupe particulier.



2.4 - TECHNIQUES DE MANIPULATION

CONCENTRATION (PACKING)

Concentrer les électeurs d'un parti adverse

Réduire leur influence dans les autres districts

Sacrifier quelques districts pour gagner ailleurs

DISPERSION (CRACKING)

Disperser les électeurs d'un parti adverse

Empêcher d'obtenir une majorité dans chaque district

Diluer leur poids électoral

FORMES BIZARRES


Districts de formes non compactes

Regrouper les électeurs favorables


Créer des circonscriptions géométriquement étranges

2.4.1 - DANS LE PRINCIPE


HOW TO STEAL AN ELECTION



50 PRECINCTS
60% BLUE
40% RED



5 DISTRICTS
5 BLUE
0 RED
BLUE WINS



5 DISTRICTS
3 RED
2 BLUE
RED WINS

**Effet de zonage appliqué
à l'électoral**

Même distribution
d'électeurs :

- Bleus : 60%
- Rouges : 40%

Résultats selon le
découpage :

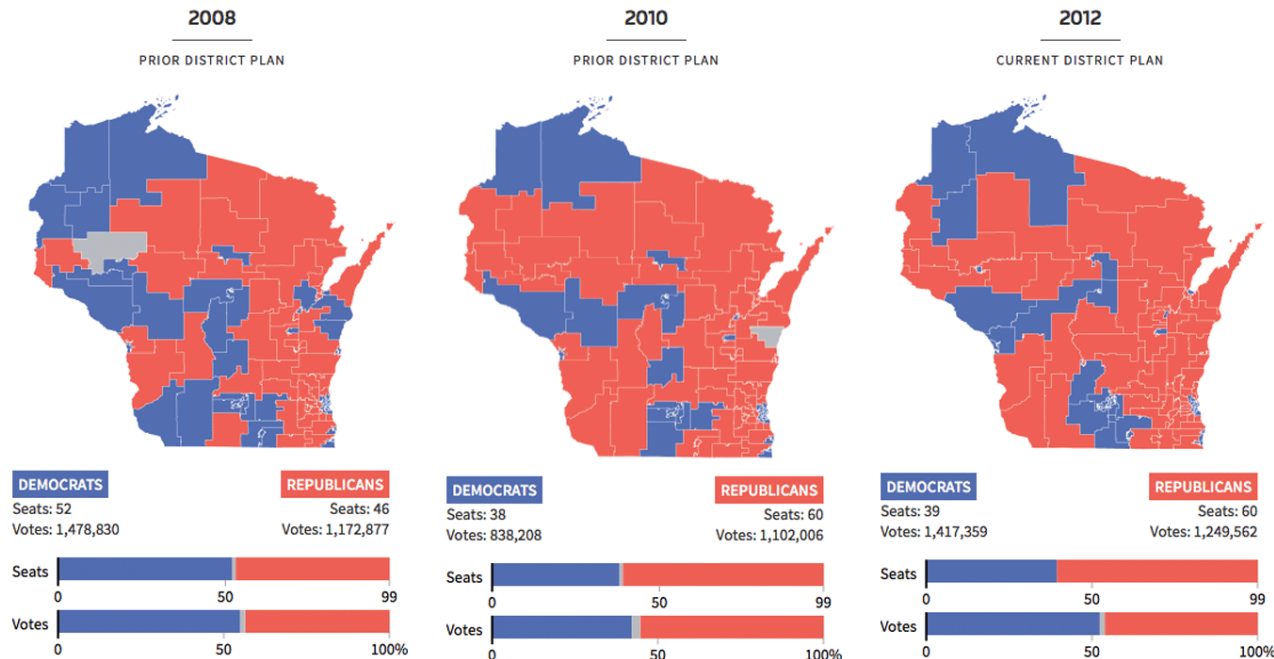
- Les rouges peuvent
gagner la majorité
malgré leur minorité

2.4.2 - DANS LA RÉALITÉ : WISCONSIN

Observez :

- La forme des circonscriptions
- Les résultats électoraux vs votes

La manipulation des frontières spatiales peut complètement changer les résultats !



3 - SOLUTIONS POUR LIMITER LE MAUP

3 - SOLUTIONS POUR LIMITER LE MAUP

Le MAUP présente un défi en analyse spatiale. Plusieurs approches permettent de minimiser son influence et d'obtenir des résultats plus robustes.

Cinq approches principales :

1. Sensibilisation au problème
2. Utilisation de données à échelle fine
3. Analyse de sensibilité
4. Techniques de régression adaptées
5. Lissage spatial et géographique

3.1 - SENSIBILISATION AU PROBLÈME

OBJECTIF

Faire prendre conscience du problème

Première étape pour minimiser l'impact du MAUP

PRINCIPE

Comprendre que le choix des unités spatiales influence les résultats

Reconnaître l'impact de la forme et de la taille des zones

Éviter les interprétations naïves des données agrégées

MISE EN PRATIQUE

Former les analystes aux enjeux du MAUP

Documenter les choix de zonage dans les rapports

Questionner systématiquement la robustesse des résultats

3.2 - DONNÉES À ÉCHELLE FINE

PRINCIPE

Utiliser des données à l'échelle la plus fine possible

Minimiser l'impact de l'agrégation

AVANTAGES

Conservation de la précision spatiale

Évite l'agrégation excessive

Permet de choisir le niveau d'agrégation optimal

LIMITES

Puissance statistique insuffisante avec petits maillages

Problèmes de confidentialité des données individuelles

Coût d'acquisition et de traitement des données fines

3.3 - ANALYSE DE SENSIBILITÉ

PRINCIPE

Évaluer l'impact du choix des unités spatiales sur les résultats

Approche importante pour tester la robustesse

MÉTHODE

Effectuer des analyses avec différentes configurations d'unités spatiales

Comparer les résultats pour identifier les zones de sensibilité

Utiliser le rapport de variance pour étudier l'effet de la configuration spatiale

RÉSULTAT

Quantification de la stabilité des résultats

Identification des paramètres sensibles au MAUP

Aide à la décision pour le choix du zonage

3.4 - TECHNIQUES DE RÉGRESSION

PRINCIPE

Réduire les biais du MAUP dans les analyses de régression

Approches adaptées aux données spatiales

RÉGRESSION SPATIALE PONDÉRÉE

Prend en compte l'autocorrélation spatiale

Pondère les observations selon leur localisation

Réduit les biais liés à l'agrégation spatiale

MODÈLES HIÉRARCHIQUES BAYÉSIENS

Combinent données agrégées et données individuelles

Modélisent les relations entre variables à différents niveaux d'agrégation

Tiennent compte de la structure hiérarchique des données spatiales

Permettent l'inférence écologique robuste

3.5 - LISSAGE GÉOGRAPHIQUE - PRINCIPE

DÉFINITION

Lissage spatial appliqué aux cartes

Représentations cartographiques simplifiées

MÉTHODE

Valeur observée remplacée par moyenne pondérée

Calcul sur le voisinage dans un rayon défini

MATRICE DE VOISINAGE

Matrice de voisinage d'ordre n

Pondération inverse de l'ordre

Fonction de pondération = compromis biais-variance

☒ EXEMPLE THÉORIQUE : MATRICE DE VOISINAGE

Ordres de voisinage (cellule centrale)

10	15	20	28	12
12	18	25	22	15
15	22	30	24	18
13	20	26	20	16
11	16	21	17	14

Cellule cible

Voisins ordre 1

Ordre 2+

Application de la pondération

Cellule centrale : 30
Voisins (ordre 1) : [22, 25, 24, 20, 26, 22, 24, 18]
Moyenne des voisins : 22.6

Pondération 50%-50% :
 $V_{\text{lissée}} = 0.5 \times 30 + 0.5 \times 22.6$
 $V_{\text{lissée}} = 26.3$

Pondération 75%-25% :
 $V_{\text{lissée}} = 0.75 \times 30 + 0.25 \times 22.6$
 $V_{\text{lissée}} = 28.2$

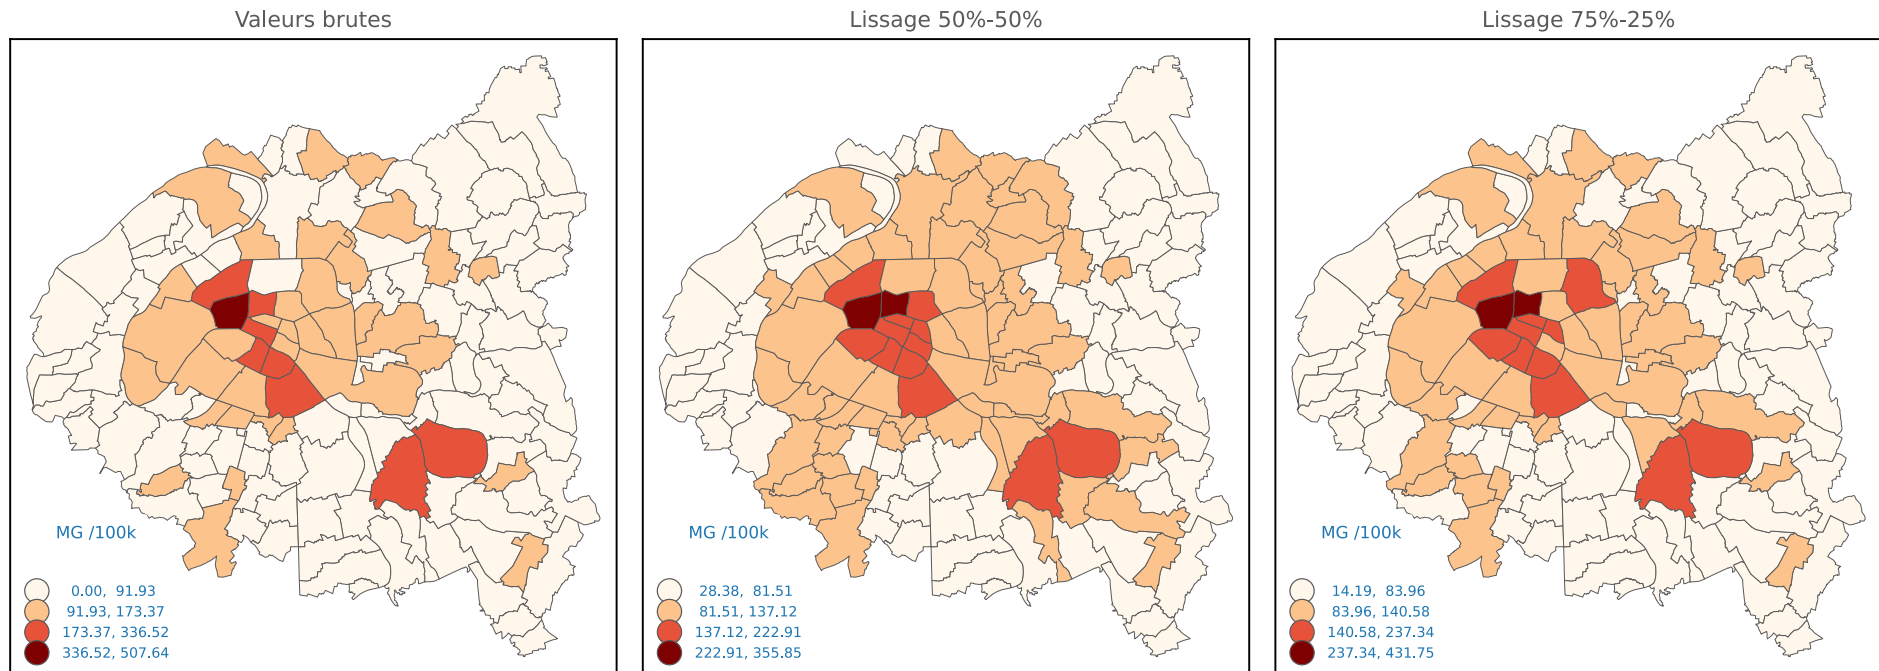
Impact : Plus le poids de la cellule centrale est élevé, moins le lissage est fort.

Ordre de voisinage : Les cellules adjacentes (partageant un côté ou un coin) sont des voisins d'ordre 1.

Pondération : Le paramètre clé contrôle l'équilibre entre la valeur propre et la moyenne des voisins.

Plus le poids est élevé pour la cellule centrale, moins le lissage est prononcé.

❧ EXEMPLE : LISSAGE AVEC MATRICE DE VOISINAGE



Matrice de voisinage Queen : Contiguïté par côtés et coins.

50%-50% : Lissage équilibré. **75%-25%** : Lissage plus conservateur (préserve davantage les valeurs locales).

Impact : Plus le poids de la cellule centrale est élevé, moins le lissage est prononcé. Le choix de la pondération dépend de l'objectif analytique.

3.6 - LE LISSAGE SPATIAL

Le **lissage spatial** est une méthode d'estimation non paramétrique de la fonction d'intensité de données ponctuelles.

Il permet de révéler des structures spatiales sous-jacentes en filtrant l'information.

S'affranchit des découpages administratifs arbitraires !

3.6 - PARAMÈTRES DU LISSAGE SPATIAL

Il s'agit d'une modélisation locale qui repose sur le choix de **deux paramètres clés** :

1. LE KERNEL

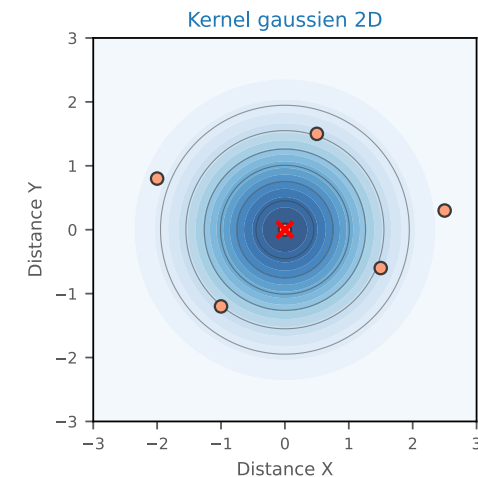

Le kernel décrit la façon dont le voisinage est appréhendé (type de fonction à l'intérieur de la fenêtre) : gaussien, uniforme, triangulaire, etc.

2. LA BANDWIDTH

La bandwidth quantifie la « taille » du voisinage.

Le choix de la bandwidth est un arbitrage entre la précision spatiale de l'analyse et sa qualité statistique (compromis biais-variance).

On peut utiliser un **histogramme de Moran** afin de choisir la distance juste **avant la chute la plus importante** de l'autocorrélation spatiale (avant la plus faible structure spatiale).





EXEMPLE DE LISSAGE SPATIAL

DONNÉES PONCTUELLES


Les médecins généralistes sont géocodés à l'adresse exacte.

APRÈS LISSAGE (KDE)

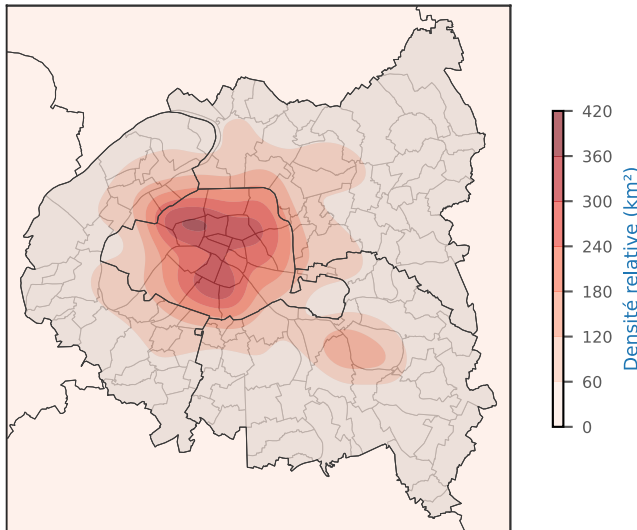
On applique un Kernel Density Estimator (KDE) :

- Fonction gaussienne
- Bandwidth 200m
- Révèle la structure spatiale sans découpage arbitraire

Médecins généralistes géocodés



Lissage spatial (KDE)



↔ 3.7 - LISSAGE SPATIAL VS GÉOGRAPHIQUE

LISSAGE SPATIAL

S'affranchit des découpages administratifs

Révèle les structures spatiales continues

Estimation non paramétrique de l'intensité

LISSAGE GÉOGRAPHIQUE

Pondération par les voisins

Appliqué aux cartes avec zonage existant

Matrice de voisinage d'ordre n

CHOIX DE LA BANDWIDTH

Histogramme de Moran pour choisir la bandwidth

Prendre la valeur juste avant la plus grande chute d'autocorrélation spatiale

Compromis biais-variance

LIMITES

Atténuent les ruptures mais peuvent masquer des phénomènes réels

Nécessitent une expertise pour paramétrer correctement

Dépendance au zonage administratif initial

CONCLUSION

LE MAUP EN PRATIQUE

CONCLUSION - LE MAUP EN PRATIQUE

NATURE DU PROBLÈME

Présent dans toute analyse spatiale

Forme et taille des unités modifient les résultats

Peut conduire à des interprétations erronées

IMPACTS OBSERVÉS

Modifie statistiques descriptives

Affecte analyses de corrélation

Impact sur inférences statistiques

APPROCHES PRATIQUES

Stratégies de minimisation nécessaires

Analyse de sensibilité recommandée

Documentation des choix méthodologiques

✓ CONCLUSION - RECOMMANDATIONS PRATIQUES

APPROCHE CONTEXTUELLE

Solution dépend du contexte

Adapter selon la question de
recherche

Tenir compte des données
disponibles

TESTS DE ROBUSTESSE

Combiner plusieurs méthodes

Tester différentes échelles

Analyser la sensibilité des résultats

DOCUMENTATION

Documenter les choix
méthodologiques

Rapporter l'impact potentiel du
MAUP

Assurer la reproductibilité de
l'analyse

BIBLIOGRAPHIE - OUVRAGES DE RÉFÉRENCE

Openshaw, S. (1984). *The Modifiable Areal Unit Problem*. Geo Books, Norwich.

Ouvrage fondateur qui explore en profondeur le MAUP, ses implications et ses effets sur les analyses spatiales.

Fotheringham, A. S., & Wong, D. W. S. (1991). "The Modifiable Areal Unit Problem in Multivariate Statistical Analysis". *Environment and Planning A*, 23(7), 1025-1044.

Article clé qui étudie le MAUP dans le contexte d'analyses multivariées, avec des exemples de l'impact du MAUP.

BIBLIOGRAPHIE - ANALYSES SPATIALES

Bailey, T. C., & Gatrell, A. C. (1995). *Interactive Spatial Data Analysis*. Longman, Essex.

Référence pour les techniques de lissage et les statistiques spatiales appliquées.

Silverman, B. W. (1986). *Density Estimation for Statistics and Data Analysis*. Chapman and Hall, London.

Ouvrage de base sur l'estimation de densité, qui décrit les méthodes de lissage par noyau (KDE).

Waller, L. A., & Gotway, C. A. (2004). *Applied Spatial Statistics for Public Health Data*. Wiley, Hoboken.

Un manuel détaillant les approches statistiques spatiales, y compris le lissage et la correction des effets de bord.

BIBLIOGRAPHIE - TECHNIQUES DE RÉGRESSION

Anselin, L. (1988). *Spatial Econometrics: Methods and Models*. Kluwer Academic Publishers, Dordrecht.

Ouvrage de référence pour les méthodes de régression spatiale.

Banerjee, S., Carlin, B. P., & Gelfand, A. E. (2014). *Hierarchical Modeling and Analysis for Spatial Data*. Chapman & Hall/CRC.

Exploration des modèles hiérarchiques bayésiens et de leurs applications en analyses spatiales.

Dark, S. J., & Bram, D. (2007). "The Modifiable Areal Unit Problem (MAUP) in Physical Geography". *Progress in Physical Geography*, 31(5), 471-479.

Article de synthèse qui explique les effets du MAUP en géographie physique.

